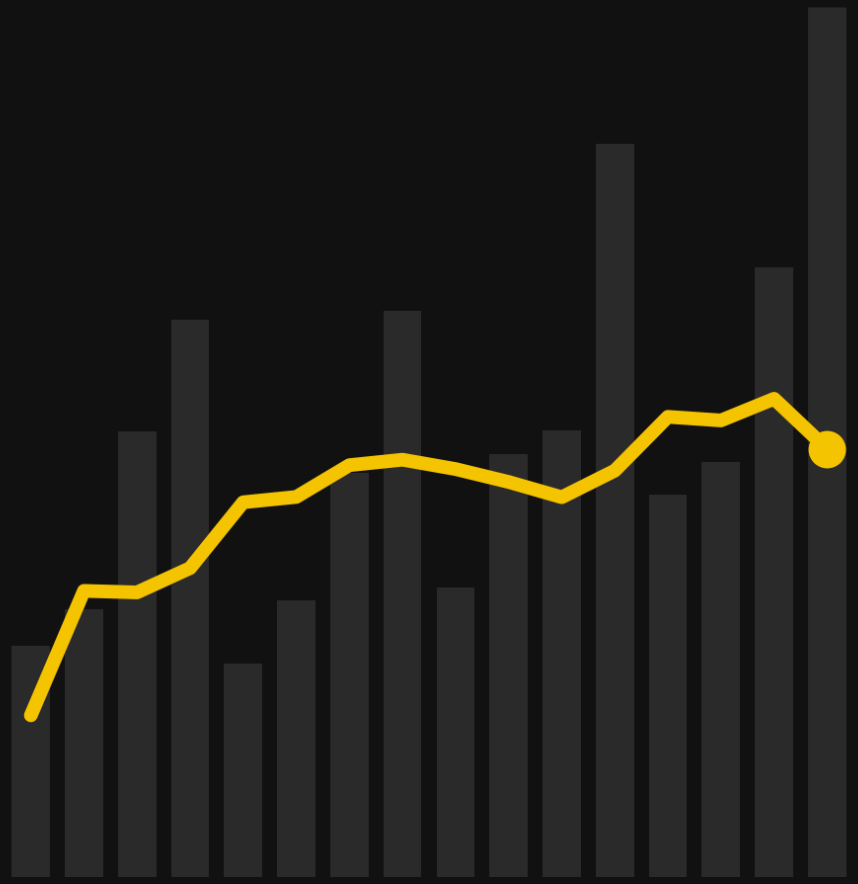
PROYECTO INTEGRADOR · APRENDIZAJE DE MÁQUINA

Rolulabo

Vendemos más, pero cada venta deja menos de lo que podría. Diagnóstico y decisión con BI y aprendizaje de máquina



Gabriel Álvarez · Eduardo Gutiérrez · Emiliano Luna · Rodrigo Naranjo Hernández

Universidad Panamericana · Noviembre 2026

RESUMEN EJECUTIVO

Recomendamos topes de descuento en 10 estados, que capturan el 91% del beneficio posible

DECISIÓN

Aplicar topes de descuento por subcategoría en los 10 estados de descuento alto, en dos olas de cinco estados que funcionan como experimento controlado.

Extender al resto del país solo si se cumplen los criterios de éxito en la semana 15.

-$36,671 a $44,770

utilidad 2017 de los 10 estados con topes, simulada con el costo real

7 de 8

creencias del negocio refutadas con datos antes de modelar

0.889 vs 0.826

F1 del modelo contra la regla actual para detectar líneas con pérdida

Fuente. Sample Superstore 2014 a 2017, simulación sobre 2017

Rolulabo vende más de $2 millones, pero casi una de cada cinco líneas pierde dinero

12.5%

margen sobre $2.3M de ventas entre 2014 y 2017

18.7%

de las líneas de venta cerró con pérdida

$156K

perdidos en esas líneas, el 35% de lo que ganaron las rentables

Además, uno de cada tres pedidos llega después de lo prometido y la empresa trata igual a todos sus clientes. El objetivo es elevar la utilidad por transacción sin quitarle a Comercial el descuento como palanca de venta.



Fuente. Sample Superstore, 9,994 líneas, 5,009 pedidos, 793 clientes

Un objetivo medible, con dueño en cada área y ligado al ODS 8

KPI del objetivo	Línea base	Meta a un año	Dueño
Líneas con pérdida	18.7%	Menos de 5%	Finanzas
Margen neto	12.7%	Más de 20%	Dirección
Promesa de entrega cumplida	67.5%	Más de 95%	Operaciones
Pedidos por cliente contra control	Base	Caída menor a 10%	Comercial

A quién beneficia. Comercial y Finanzas deciden los descuentos, Operaciones la promesa de entrega, Marketing el presupuesto por cliente y Dirección aprueba la política.

Por qué importa. Las pérdidas se ven hasta el cierre contable. En simulación, los topes llevarían el margen de 2017 a 22.2%.

ODS 8

Trabajo decente y crecimiento económico, meta 8.2

La meta busca elevar la productividad con modernización tecnológica e innovación. El proyecto sube la utilidad por transacción con datos que la empresa ya tiene.

La relación es indirecta y a nivel empresa. No usamos ODS ambientales porque los datos no traen consumo de recursos.

Línea base de reports/metrics, margen de 2017 y el resto de 2014 a 2017. El piloto de la decisión verifica las metas

METODOLOGÍA

Seguimos CRISP-DM en tres iteraciones ágiles, cada una con un entregable que funciona

1

Negocio

KPIs e historias de usuario

2

Datos

EDA y 8 hipótesis probadas

3

Preparación

ETL validado y modelo estrella

4

Modelado

Cuatro modelos, validación temporal

5

Evaluación

Contra línea base y simulación

6

Despliegue

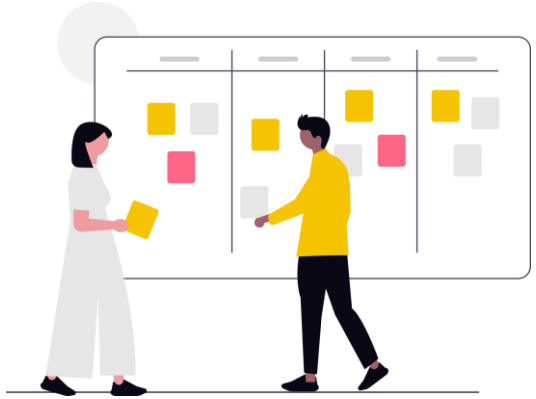
Dashboard por área y monitoreo

Iteración	Fases	Entregable	Qué cambió al cerrar
1. Negocio y datos	1, 2, 3	ETL validado, EDA, hipótesis	H1 cayó. Ya no es capacitar vendedores, es corregir una tabla
2. Modelos	4, 5	Cuatro modelos contra tres líneas base	H5 cayó. Operaciones pasó de priorizar pedidos a ajustar la promesa
3. Decisión y despliegue	5, 6	Simulación, dashboard, decisión	H2 cayó. El riesgo de perder volumen con topes resultó bajo

Definición de terminado. Se regenera con un comando, se compara contra una línea base y está ligado a una decisión

Cada pregunta analítica nace de una historia de usuario de un área

Historia de usuario	Criterio de aceptación	Estado
Como gerente comercial quiero saber antes de cerrar si una línea perderá dinero, para ajustar el descuento	Modelo mejor que la regla actual en F1, con intervalo de confianza	Terminada
Como director de finanzas quiero un tope de descuento por subcategoría con su impacto, para aprobar la política	Topes calculados sin usar 2017 y simulados sobre 2017	Terminada
Como gerente de operaciones quiero saber qué pedidos llegarán tarde, para priorizarlos	**AUC mayor a 0.65 en 2017**	**Replanteada**
Como gerente de marketing quiero grupos de clientes con su rentabilidad, para asignar presupuesto	Grupos estables y con perfil accionable	Terminada
Como director general quiero una sola lectura de las causas, para decidir dónde actuar	Decisión con opciones, impacto y criterios	Terminada



La historia de Operaciones se replanteó porque el AUC fue 0.5. Se entrega una promesa realista en su lugar

Datos públicos y limpios, con sus atípicos y sesgos a la vista

Validación	Resultado
Fuente	Superstore, Kaggle
Líneas y columnas	9,994 y 21
Valores faltantes	0
Duplicados exactos	1, eliminado
Pedidos inconsistentes	0
Product ID para dos productos	32, llave ID y nombre
Costo constante por producto	Sí, pérdida determinista

ATÍPICOS

11.7% de las ventas y 18.8% de las utilidades por línea están fuera del rango de Tukey. Son ventas reales y no se eliminan. Precio en logaritmo, modelos de árboles y margen recortado en p1 y p99.

SESGOS

Representatividad, West 32% de las líneas y South 16%. Confusión, el descuento es fijo por estado y subcategoría. Selección, solo hay ventas cerradas y no se ve a quien no compró. Datos sintéticos.

Validaciones en src/etl.py, resultado en reports/metrics/data_quality.json. Fuente kaggle.com/datasets/vivek468/superstore-dataset-final

7 de 8 creencias del negocio resultaron falsas al probarlas con datos

	Creencia del negocio	Evidencia	Resultado
H1	El descuento lo decide cada vendedor en cada venta	656 de 656 combinaciones estado y subcategoría tienen un solo descuento	**Refutada**
H2	Dar más descuento hace que el cliente compre más unidades	rho = -0.001, p = 0.94. Misma cantidad con 0% y con 80%	**Refutada**
H3	Las pérdidas vienen de cierto tipo de cliente (Consumer, Corporate, Home Office)	Pérdida de 17.5% a 19.3% por segmento, p = 0.19, V = 0.02	**Refutada**
H4	Las pérdidas se concentran en el cuarto trimestre por promociones de temporada	Pérdida de 17.5% a 19.3% por trimestre, p = 0.29	**Refutada**
H5	Los retrasos se concentran en ciertas regiones, categorías o meses	0 de 24 pruebas significativas, AUC de 0.46 a 0.52	**Refutada**
H6	Los clientes que dejaron de comprar se fueron por entregas tardías	Inactivos 28% de pedidos tarde contra 33% de los activos, p una cola = 0.98	**Refutada**
H7	Los clientes que más compran son los más rentables	Ventas contra margen rho = 0.04. Descuento contra margen rho = -0.59	**Refutada**
H8	Un modelo de aprendizaje de máquina detecta pérdidas mejor que una regla de negocio simple	F1 0.889 contra 0.826, intervalos de 95% sin traslape	**Confirmada**

Cada veredicto sale de un criterio fijado antes, alfa 0.05. Spearman, Kruskal-Wallis, chi-cuadrada, Mann-Whitney, Bonferroni y bootstrap

INSIGHT 1 · H1 REFUTADA

La pérdida es una política, no un error del vendedor

EL DESCUENTO ES UNA TABLA

656 de 656 combinaciones de estado y subcategoría tienen un solo descuento

El vendedor no decide, hereda. Illinois, Texas, Pennsylvania y Ohio promedian de 32% a 39%.

LA PÉRDIDA ES DETERMINISTA

Una línea pierde cuando el descuento supera 1 menos costo entre precio

Esa regla explica el 100% de las pérdidas y permite simular cualquier política.

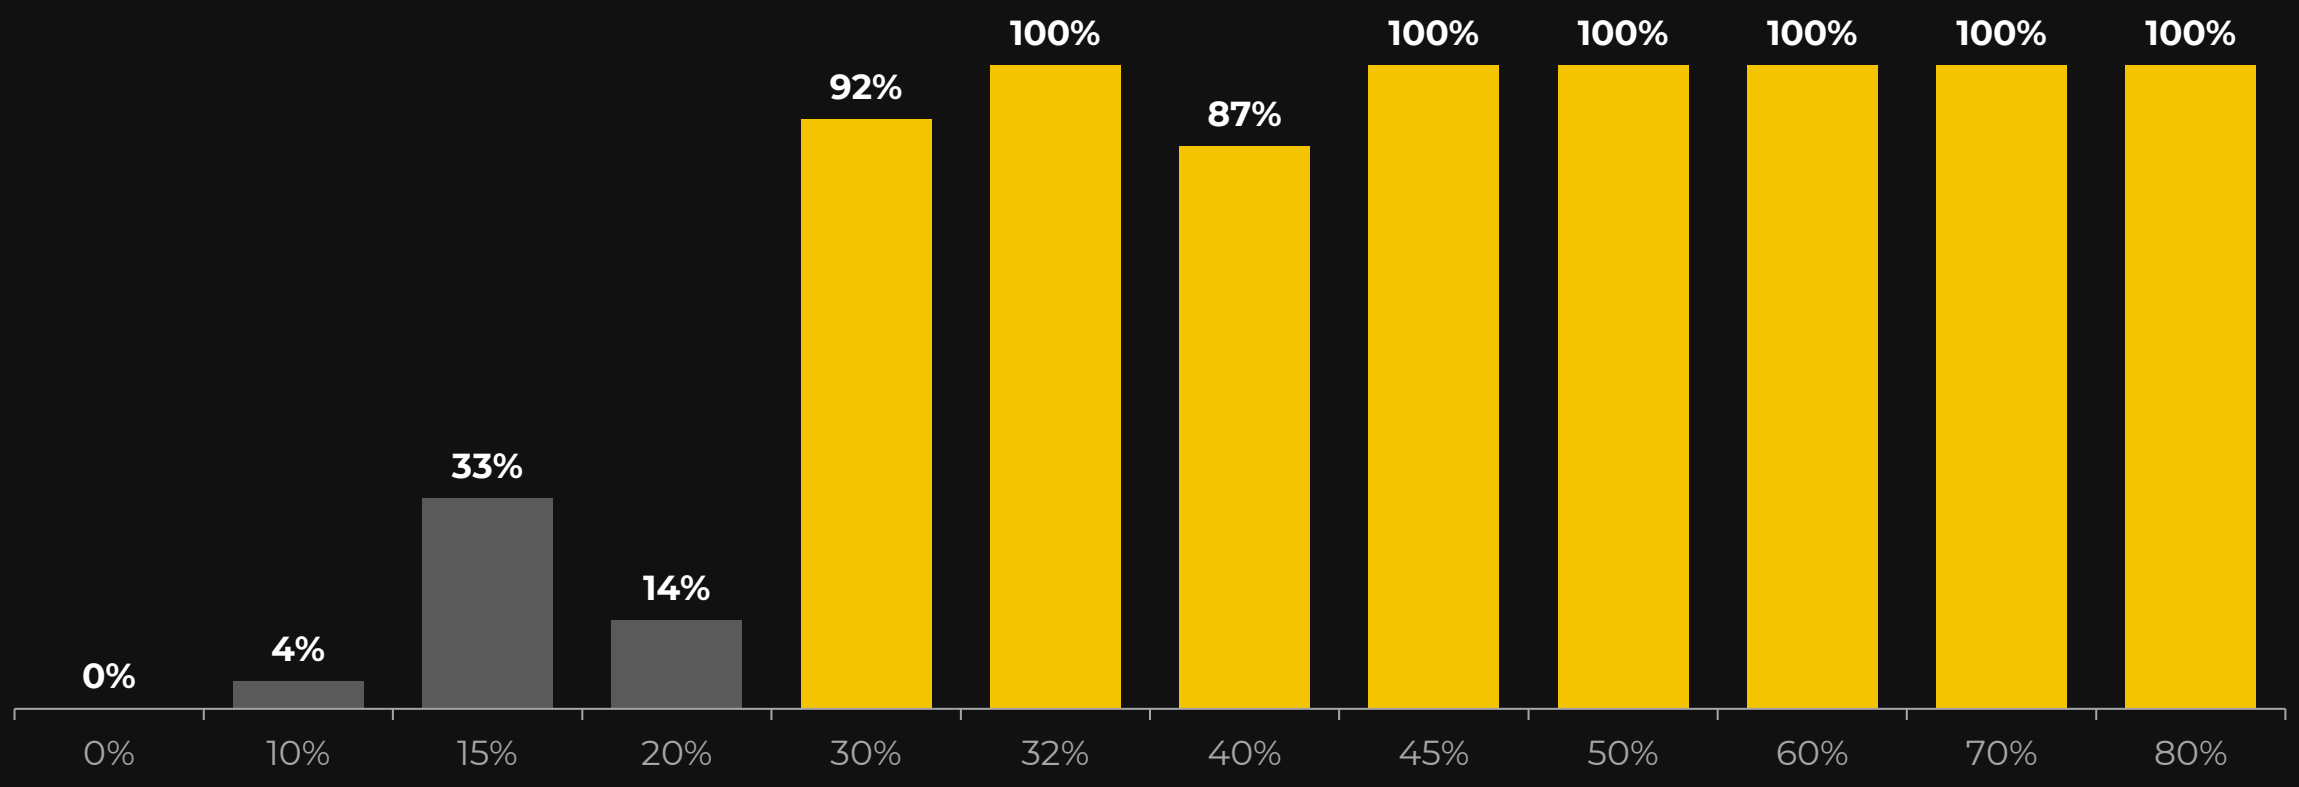
Los 10 estados en amarillo concentran el **93%** de las pérdidas con 39% de las líneas.



En amarillo, estados con descuento promedio mayor a 25% y su pérdida bruta 2014 a 2017

INSIGHT 1 · EVIDENCIA

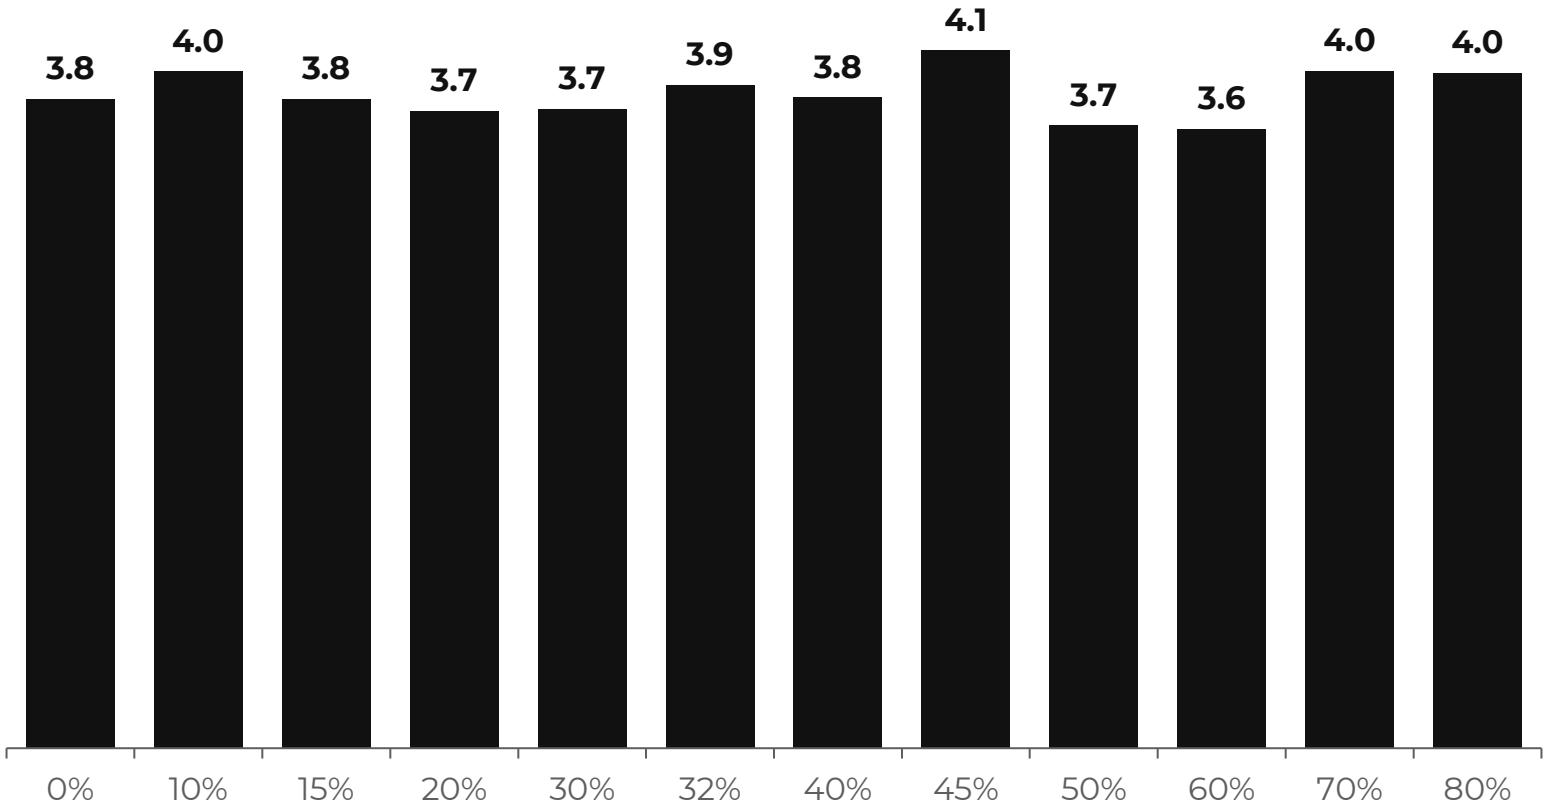
Arriba de 20% de descuento casi todas las líneas pierden dinero



Proporción de líneas con pérdida por nivel de descuento, 2014 a 2017. Eje horizontal, descuento aplicado

INSIGHT 2 · H2 REFUTADA

El descuento no compra volumen, el cliente lleva lo mismo con 0% que con 80%



CORRELACIÓN DE SPEARMAN

rho = -0.001

p = 0.94, Kruskal-Wallis p = 0.53

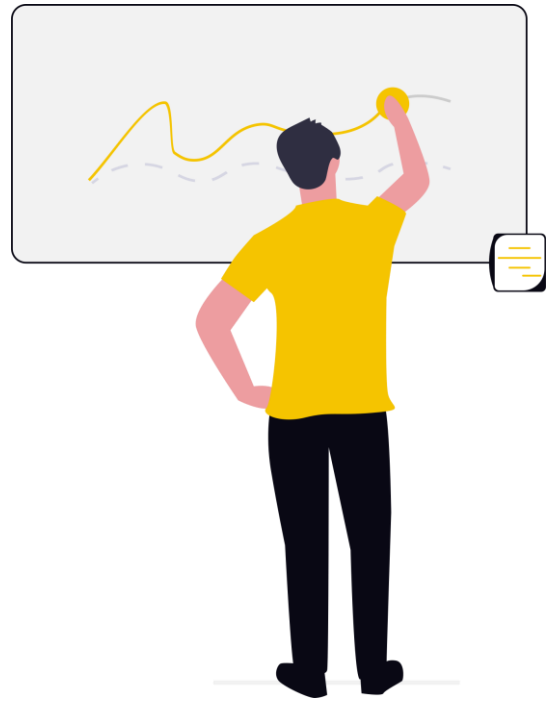
Quitar descuento donde genera pérdida tiene poco riesgo de perder ventas. Es la objeción principal a los topes y los datos no la sostienen.

Unidades promedio por línea según nivel de descuento, 2014 a 2017

El gradient boosting supera a la regla de negocio en F1 y PR-AUC

Sin utilidad, margen ni costo para evitar fuga. Entrenamiento 2014 a 2016, prueba 2017.
Hiperparámetros y umbral con validación cruzada temporal.

Modelo	PR-AUC	F1	Precisión	Recall	Pérdida detectada
Regla descuento mayor a 20%	0.814	0.826	0.976	0.716	89%
Regresión logística	0.945	0.841	0.846	0.835	94%
Árbol de decisión	0.944	0.859	0.919	0.806	92%
Random forest	0.957	0.864	0.814	0.919	98%
Gradient boosting, elegido	**0.967**	**0.889**	**0.905**	**0.874**	**96%**
Regla con costo histórico, sin ML	0.997	0.995	0.995	0.995	100%



IC 95% de F1 por bootstrap. Modelo 0.871 a 0.906, regla 0.802 a 0.851. La última fila es referencia, usa el costo del producto

INSIGHT 3 · H8 CONFIRMADA

El modelo encuentra las pérdidas que la regla no ve con 20% de descuento

169

pérdidas en 2017 con exactamente 20% de descuento, de 1,223 líneas

0

detectadas por la regla de negocio

94

detectadas por el modelo, con 45 falsas alarmas

Importancia por permutación. Descuento 0.74, subcategoría 0.09, precio 0.04. Región, segmento y envío no aportan, la pérdida depende del producto y del descuento.

Fuente. reports/metrics/loss_model.json, prueba 2017

Dónde falla el modelo, qué tan firme es y cuándo no hace falta

DÓNDE SE EQUIVOCA

78

pérdidas no detectadas, el 96% con 20% de descuento. Suman el 3.7% del monto perdido. Las 57 falsas alarmas tenían $1,146 de utilidad.

QUÉ TAN FIRME ES

0.884 a 0.890

F1 si el umbral se mueve 0.10. Intervalo bootstrap de 0.871 a 0.906. Los mismos números en cada corrida, una prueba automática lo exige.

CUÁNDO NO HACE FALTA

0.995

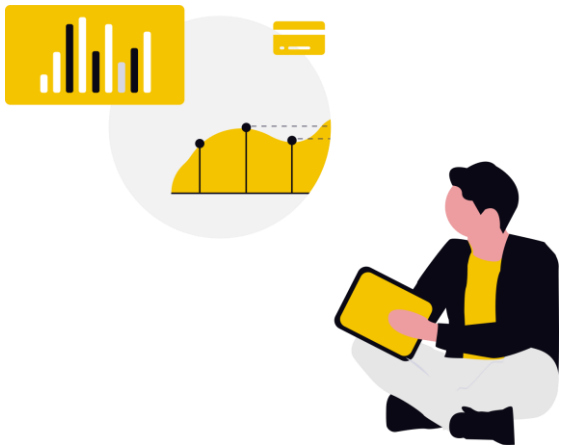
F1 de una regla con el costo histórico de cada producto, sin ML. El 97% de las líneas de 2017 tiene historial. Si el sistema expone el costo, se usa la regla.

Lectura. El modelo sirve donde no hay costo, como segundo método para fijar topes y para confirmar sin costo que la pérdida depende del descuento y la subcategoría. La decisión no depende del clasificador.

Errores y sensibilidad en reports/metrics/loss_model.json, prueba 2017

Ocho subcategorías concentran la utilidad que se recupera con topes

Subcategoría	Desc. promedio	Desc. máximo	Líneas con pérdida	Tope	Recupera 2017
Binders	37%	80%	40%	**30%**	$26,078
Tables	26%	50%	63%	**10%**	$17,035
Machines	31%	70%	40%	**25%**	$11,570
Chairs	17%	30%	36%	**10%**	$9,929
Bookcases	21%	70%	47%	**5%**	$6,510
Storage	7%	20%	19%	**0%**	$5,030
Phones	15%	40%	14%	**25%**	$3,643
Appliances	16%	80%	13%	**25%**	$2,804



Tope = menor entre el percentil 10 del descuento de equilibrio y el tope del modelo. Calculado solo con 2014 a 2016

Con topes, la utilidad de 2017 casi se duplica y conviene aun perdiendo volumen

Utilidad 2017

$93K → **$183K**

Líneas con pérdida

620 → **49**

El tope cambia 925 líneas, el 28% del año.

Sensibilidad a pérdida de volumen

Volumen perdido en líneas afectadas	Utilidad extra
0%	+$89,220
10%	+$84,904
25%	+$78,430
50%	+$67,639
100%	**+$46,058**

Las líneas afectadas perdían $46,058 en conjunto. Aun perdiéndolas todas, la política conviene.

Utilidad recalculada con el costo unitario real de cada producto. Supuesto principal, volumen constante

CÓMO SE USA EL MODELO

El modelo calcula, la regla recomienda y una persona decide

1 · SCORE

Probabilidad de pérdida

El gradient boosting la calcula al capturar el pedido

2 · REGLA

Semáforo auditable

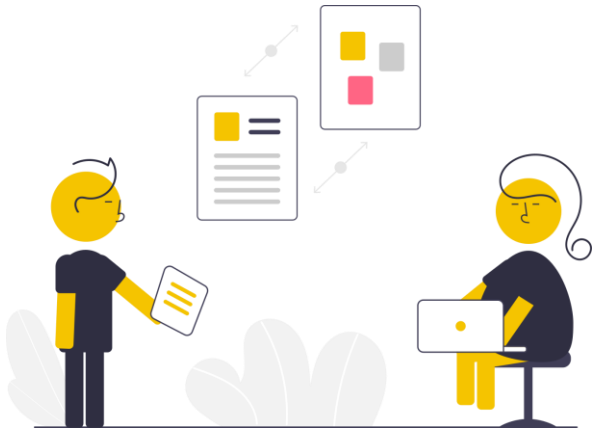
Rojo si supera el tope. Amarillo si el score pasa 0.45. Verde en otro caso

3 · DECISIÓN HUMANA

Gerente comercial

Ajusta, aprueba una excepción con justificación o rechaza. Queda en bitácora

Semáforo 2017	Líneas	Por mes	Tasa de pérdida	Monto perdido
Rojo	925	77	65%	99.2%
Amarillo	4	0	75%	0.1%
Verde	2,383	199	1%	0.7%



Revisión humana en 28% de las líneas, unas 77 al mes, que cubren el 99.3% del monto perdido

INSIGHT 4 · H5 Y H6 REFUTADAS

El retraso no se puede predecir, el problema está en la promesa

0 de 24

pruebas chi-cuadrada significativas con Bonferroni. AUC de 0.46 a 0.52 dentro de cada modalidad

Tampoco explica el abandono. Los clientes inactivos tuvieron menos retrasos (28%) que los activos (33%). Mejorar envíos no recupera clientes.



Modalidad	Promesa hoy	Cumple hoy	Promesa nueva	Cumpliría
Same Day	0 días	95%	0 días	95%
First Class	2 días	60%	3 días	100%
Second Class	**3 días**	**59%**	**5 días**	**100%**
Standard Class	5 días	70%	7 días	100%

Second Class tarda 4 o 5 días el 41% de las veces, lo que hoy se espera de Standard Class. Para poder predecir después hay que registrar transportista, almacén y fecha real de entrega.

Promesa nueva = percentil 95 de días de envío por modalidad. Promesa actual es un supuesto del equipo

INSIGHT 5 · H7 REFUTADA

Vender mucho no es ser rentable, cuatro grupos y uno destruye margen

Alto valor rentable

347

clientes

Margen 18.4%
Descuento 12.4%
65% de las ventas
29% de las pérdidas

Cazadores de descuento

201

clientes

Margen -5.4%
Descuento 24.4%
23% de las ventas
62% de las pérdidas

Compradores ocasionales

172

clientes

Margen 21.0%
Descuento 10.0%
8% de las ventas
2% de las pérdidas

Inactivos

73

clientes

Margen -0.2%
Descuento 21.6%
4% de las ventas
7% de las pérdidas

K-Means sobre recencia, frecuencia, monto, margen y descuento. k = 4, silueta 0.22, ARI bootstrap 0.72

SÍNTESIS

Seis insights, cada uno con su acción

La pérdida es una política

Reescribir la tabla de descuentos de 10 estados

El descuento no compra volumen

Aplicar topes con un piloto que mida el efecto real

Vender mucho no es ser rentable

Ofrecer servicio y no precio a los Cazadores

El modelo ve la zona gris del 20%

Usarlo donde no hay costo del producto

El retraso es un problema de promesa

Prometer 3, 5 y 7 días y registrar entregas

La segmentación oficial no sirve

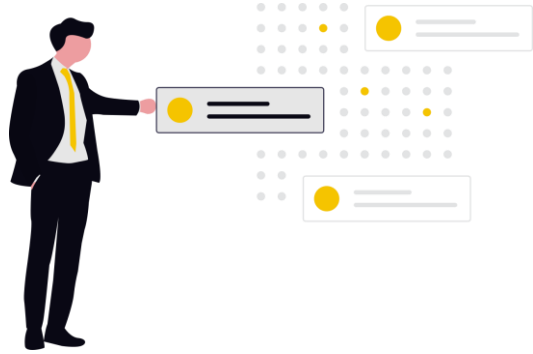
Presupuestar marketing con los cuatro grupos

Cada insight sale de una hipótesis probada o de un modelo evaluado contra línea base

Evaluamos tres opciones y recomendamos la C

Opción	Utilidad 2017 simulada	Riesgo
A. Mantener la política actual	$93,439	Sigue perdiendo dinero en 10 estados
B. Topes en todo el país de inmediato	$182,660	No mide el efecto real en volumen antes de escalar
C. Topes en los 10 estados en dos olas, el resto después	**$174,880**	**Bajo. La primera ola sirve de experimento contra la segunda**

Por qué C y no B. Captura el 91% del beneficio con 815 de las 925 líneas afectadas, y mide el efecto real en volumen antes de escalar. Mientras corre la primera ola, la segunda funciona como grupo de control. Es reversible porque solo cambia una tabla.



Utilidad simulada con el costo real de 2017 y volumen constante

DECISIÓN

Topes de descuento en los 10 estados de descuento alto, en dos olas, a partir del siguiente trimestre

Semanas 1 a 2

Finanzas aprueba la tabla y se carga en el sistema

Semanas 3 a 8

Ola 1 en cinco estados, los otros cinco de control

Semanas 9 a 14

Ola 2 en los cinco restantes

Semana 15

Dirección revisa y decide extender al país

Criterios de éxito

Líneas con pérdida menores a 5% en estados tratados. Pedidos por cliente sin caer más de 10% contra control. Margen positivo en los 10 estados.

Criterio de alto

Si los pedidos por cliente caen más de 25% contra el control, se revisan los topes antes de la segunda ola. En paralelo, nueva promesa de entrega y campañas por grupo.

La solución vive como producto de BI con modelos integrados



Monitoreo	Regla
Reentrenamiento	Cada trimestre con datos nuevos, recalculando los topes
Deriva	Vigilar la distribución del descuento y del precio de lista
Alerta de negocio	Líneas con pérdida mayores a 5% en cualquier estado
Alerta de modelo	F1 del trimestre por debajo del de la regla simple

El modelo estrella se conecta igual a Power BI, Looker Studio o Tableau. data/processed/bi

Los límites están acotados y todo se regenera con un comando

Datos sintéticos. La utilidad sale de una fórmula con costo fijo. Con fletes y devoluciones las métricas bajarían.

El costo explica la pérdida. Con el costo del producto una regla llega a F1 0.995, el modelo no es indispensable.

Volumen por línea. No vemos a quien no compró, por eso el piloto con grupo de control.

Promesa supuesta. La recomendación usa la distribución real de días, no la tasa.

Grupos con frontera difusa. Silueta 0.22, los perfiles son tendencias.

Un país, cuatro años. No se valida en otro mercado.

Se regenera en 35 segundos

```
uv sync

uv run python src/run_all.py

uv run pytest -q
```

Versiones fijas en uv.lock y una prueba que exige los mismos números en cada corrida. El notebook corre en Google Colab.

ROLULABO

Preguntas

Menos descuento donde no se paga, una promesa de entrega honesta y una estrategia distinta para cada grupo de clientes.



Herramientas e IA. Python, scikit-learn y uv. Claude (Anthropic) como asistente para código, revisión metodológica y borradores. Las decisiones, la ejecución y la interpretación son del equipo, y las verificaciones están en la Declaración de herramientas. Datos, Sample Superstore, Kaggle.