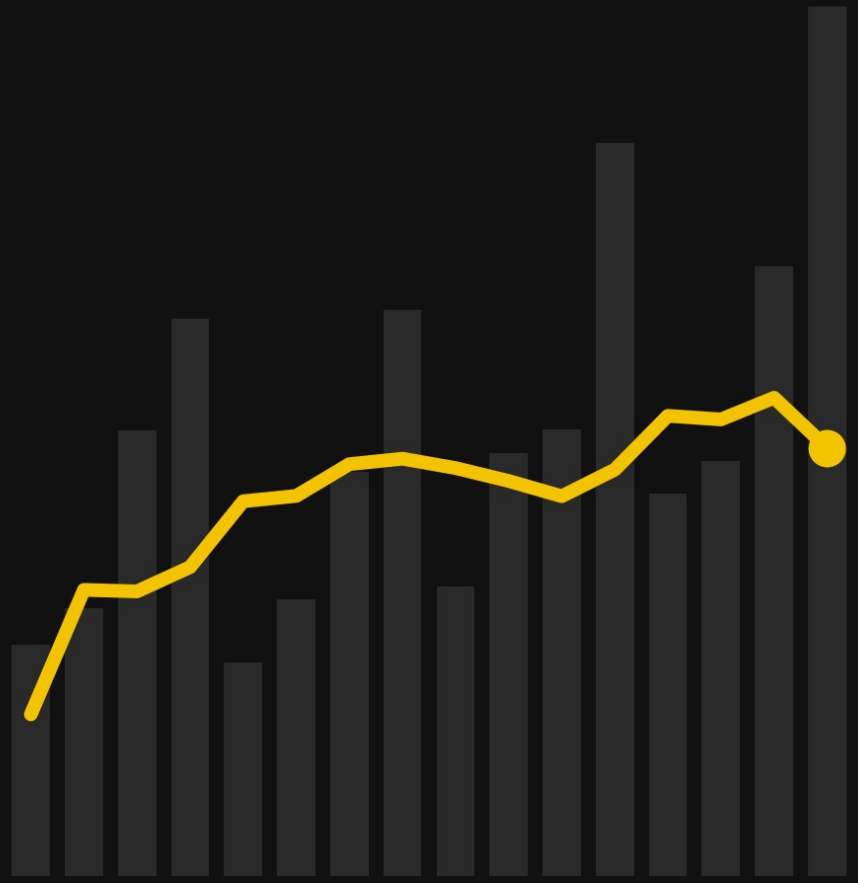
PROYECTO INTEGRADOR · APRENDIZAJE DE MÁQUINA

# Rolulabo

Vendemos más, pero cada venta deja menos de lo que podría. Diagnóstico y decisión con BI y aprendizaje de máquina



Gabriel Álvarez · Eduardo Gutiérrez · Emiliano Luna · Rodrigo Naranjo Hernández

Universidad Panamericana · Noviembre 2026

RESUMEN EJECUTIVO

# Recomendamos topes de descuento en 10 estados, que capturan el 91% del beneficio posible

**DECISIÓN**

Aplicar topes de descuento por subcategoría en los 10 estados de descuento alto, en dos olas de cinco estados que funcionan como experimento controlado.

Extender al resto del país solo si se cumplen los criterios de éxito en la semana 15.

**-$36,671 a $44,770**

utilidad 2017 de los 10 estados con topes, simulada con el costo real

**7 de 8**

creencias del negocio refutadas con datos antes de modelar

**0.889 vs 0.826**

F1 del modelo contra la regla actual para detectar líneas con pérdida

Fuente. Sample Superstore 2014 a 2017, simulación sobre 2017

# Rolulabo vende más de $2 millones, pero casi una de cada cinco líneas pierde dinero

**12.5%**

margen sobre $2.3M de ventas entre 2014 y 2017

**18.7%**

de las líneas de venta cerró con pérdida

**$156K**

perdidos en esas líneas, el 35% de lo que ganaron las rentables

Además, uno de cada tres pedidos llega después de lo prometido y la empresa trata igual a todos sus clientes. El objetivo es elevar la utilidad por transacción sin quitarle a Comercial el descuento como palanca de venta.




Fuente. Sample Superstore, 9,994 líneas, 5,009 pedidos, 793 clientes

# Un objetivo medible, con dueño en cada área y ligado al ODS 8

| KPI del objetivo | Línea base | Meta a un año | Dueño |
|---|---|---|---|
| **Líneas con pérdida** | 18.7% | Menos de 5% | Finanzas |
| **Margen neto** | 12.7% | Más de 20% | Dirección |
| **Promesa de entrega cumplida** | 67.5% | Más de 95% | Operaciones |
| **Pedidos por cliente contra control** | Base | Caída menor a 10% | Comercial |

**A quién beneficia.** Comercial y Finanzas deciden los descuentos, Operaciones la promesa de entrega, Marketing el presupuesto por cliente y Dirección aprueba la política.

**Por qué importa.** Las pérdidas se ven hasta el cierre contable. En simulación, los topes llevarían el margen de 2017 a 22.2%.

## ODS 8

**Trabajo decente y crecimiento económico, meta 8.2**

La meta busca elevar la productividad con modernización tecnológica e innovación. El proyecto sube la utilidad por transacción con datos que la empresa ya tiene.

La relación es indirecta y a nivel empresa. No usamos ODS ambientales porque los datos no traen consumo de recursos.

Línea base de reports/metrics, margen de 2017 y el resto de 2014 a 2017. El piloto de la decisión verifica las metas

METODOLOGÍA

# Seguimos CRISP-DM en tres iteraciones ágiles, cada una con un entregable que funciona

1
**Negocio**
KPIs e historias de usuario

2
**Datos**
EDA y 8 hipótesis probadas

3
**Preparación**
ETL validado y modelo estrella

4
**Modelado**
Tres modelos, validación temporal

5
**Evaluación**
Contra línea base y simulación

6
**Despliegue**
Dashboard por área y monitoreo

| Iteración | Fases | Entregable | Qué cambió al cerrar |
|---|---|---|---|
| **1. Negocio y datos** | 1, 2, 3 | ETL validado, EDA, hipótesis | H1 cayó. Ya no es capacitar vendedores, es corregir una tabla |
| **2. Modelos** | 4, 5 | Tres modelos contra línea base | H5 cayó. Operaciones pasó de priorizar pedidos a ajustar la promesa |
| **3. Decisión y despliegue** | 5, 6 | Simulación, dashboard, decisión | H2 cayó. El riesgo de perder volumen con topes resultó bajo |

Definición de terminado. Se regenera con un comando, se compara contra una línea base y está ligado a una decisión

# Cada pregunta analítica nace de una historia de usuario de un área

| Historia de usuario | Criterio de aceptación | Estado |
|---|---|---|
| Como gerente comercial quiero saber antes de cerrar si una línea perderá dinero, para ajustar el descuento | Modelo mejor que la regla actual en F1, con intervalo de confianza | Terminada |
| Como director de finanzas quiero un tope de descuento por subcategoría con su impacto, para aprobar la política | Topes calculados sin usar 2017 y simulados sobre 2017 | Terminada |
| **Como gerente de operaciones quiero saber qué pedidos llegarán tarde, para priorizarlos** | **AUC mayor a 0.65 en 2017** | **Replanteada** |
| Como gerente de marketing quiero grupos de clientes con su rentabilidad, para asignar presupuesto | Grupos estables y con perfil accionable | Terminada |
| Como director general quiero una sola lectura de las causas, para decidir dónde actuar | Decisión con opciones, impacto y criterios | Terminada |



La historia de Operaciones se replanteó porque el AUC fue 0.5. Se entrega una promesa realista en su lugar

# Datos públicos y limpios, con sus atípicos y sesgos a la vista

| Validación | Resultado |
|---|---|
| **Fuente** | Superstore, Kaggle |
| **Líneas y columnas** | 9,994 y 21 |
| **Valores faltantes** | 0 |
| **Duplicados exactos** | 1, eliminado |
| **Pedidos inconsistentes** | 0 |
| **Product ID para dos productos** | 32, llave ID y nombre |
| **Costo constante por producto** | Sí, pérdida determinista |

**ATÍPICOS**

11.7% de las ventas y 18.8% de las utilidades por línea están fuera del rango de Tukey. Son ventas reales y no se eliminan. Precio en logaritmo, modelos de árboles y margen recortado en p1 y p99.

**SESGOS**

Representatividad, West 32% de las líneas y South 16%. Confusión, el descuento es fijo por estado y subcategoría. Selección, solo hay ventas cerradas y no se ve a quien no compró. Datos sintéticos.

Validaciones en src/etl.py, resultado en reports/metrics/data_quality.json. Fuente kaggle.com/datasets/vivek468/superstore-dataset-final

# 7 de 8 creencias del negocio resultaron falsas al probarlas con datos

| | Creencia del negocio | Evidencia | Resultado |
|---|---|---|---|
| **H1** | El descuento lo decide cada vendedor en cada venta | 656 de 656 combinaciones estado y subcategoría tienen un solo descuento | **Refutada** |
| **H2** | Dar más descuento hace que el cliente compre más unidades | rho = -0.001, p = 0.94. Misma cantidad con 0% y con 80% | **Refutada** |
| **H3** | Las pérdidas vienen de cierto tipo de cliente (Consumer, Corporate, Home Office) | Pérdida de 17.5% a 19.3% por segmento, p = 0.19, V = 0.02 | **Refutada** |
| **H4** | Las pérdidas se concentran en el cuarto trimestre por promociones de temporada | Pérdida de 17.5% a 19.3% por trimestre, p = 0.29 | **Refutada** |
| **H5** | Los retrasos se concentran en ciertas regiones, categorías o meses | 0 de 24 pruebas significativas, AUC de 0.46 a 0.52 | **Refutada** |
| **H6** | Los clientes que dejaron de comprar se fueron por entregas tardías | Inactivos 28% de pedidos tarde contra 33% de los activos, p una cola = 0.98 | **Refutada** |
| **H7** | Los clientes que más compran son los más rentables | Ventas contra margen rho = 0.04. Descuento contra margen rho = -0.59 | **Refutada** |
| **H8** | Un modelo de aprendizaje de máquina detecta pérdidas mejor que una regla de negocio simple | F1 0.889 contra 0.826, intervalos de 95% sin traslape | **Confirmada** |

Cada veredicto sale de un criterio fijado antes, alfa 0.05. Spearman, Kruskal-Wallis, chi-cuadrada, Mann-Whitney, Bonferroni y bootstrap

INSIGHT 1 · H1 REFUTADA

# La pérdida es una política, no un error del vendedor

EL DESCUENTO ES UNA TABLA

## 656 de 656 combinaciones de estado y subcategoría tienen un solo descuento

El vendedor no decide, hereda. Illinois, Texas, Pennsylvania y Ohio promedian de 32% a 39%.

LA PÉRDIDA ES DETERMINISTA

## Una línea pierde cuando el descuento supera 1 menos costo entre precio

Esa regla explica el 100% de las pérdidas y permite simular cualquier política.

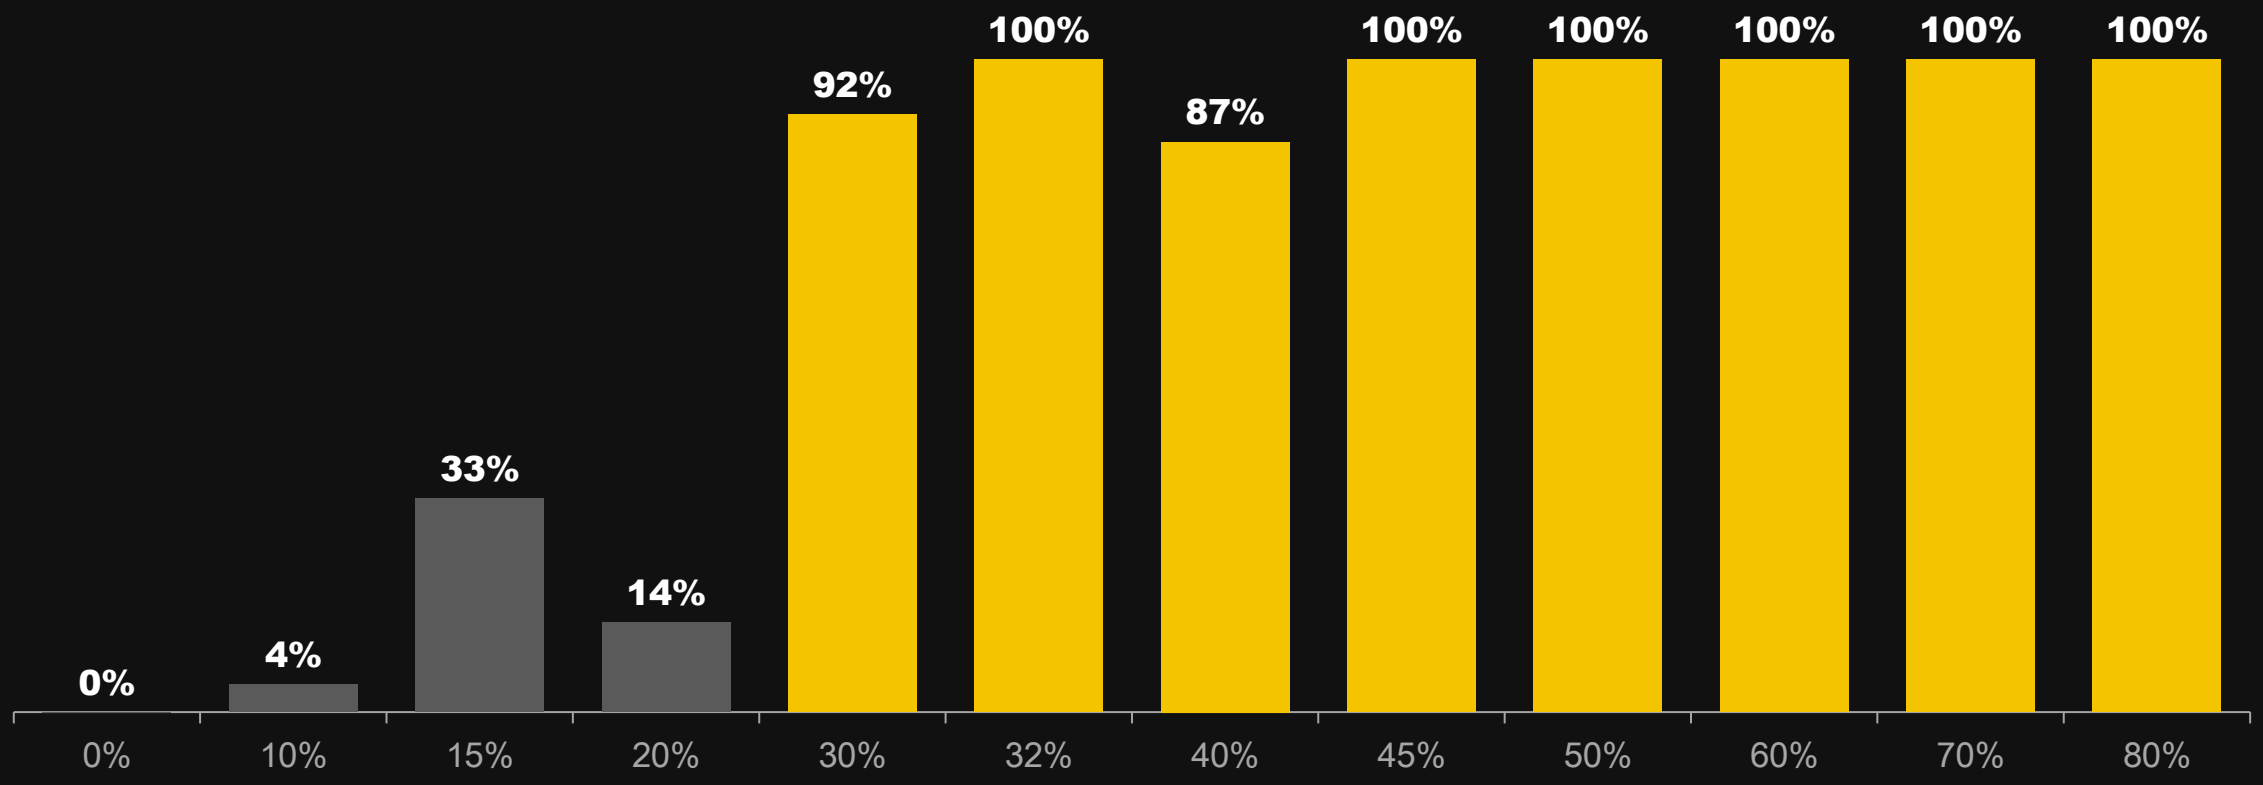
Los 10 estados en amarillo concentran el **93%** de las pérdidas con 39% de las líneas.




En amarillo, estados con descuento promedio mayor a 25% y su pérdida bruta 2014 a 2017

INSIGHT 1 · EVIDENCIA

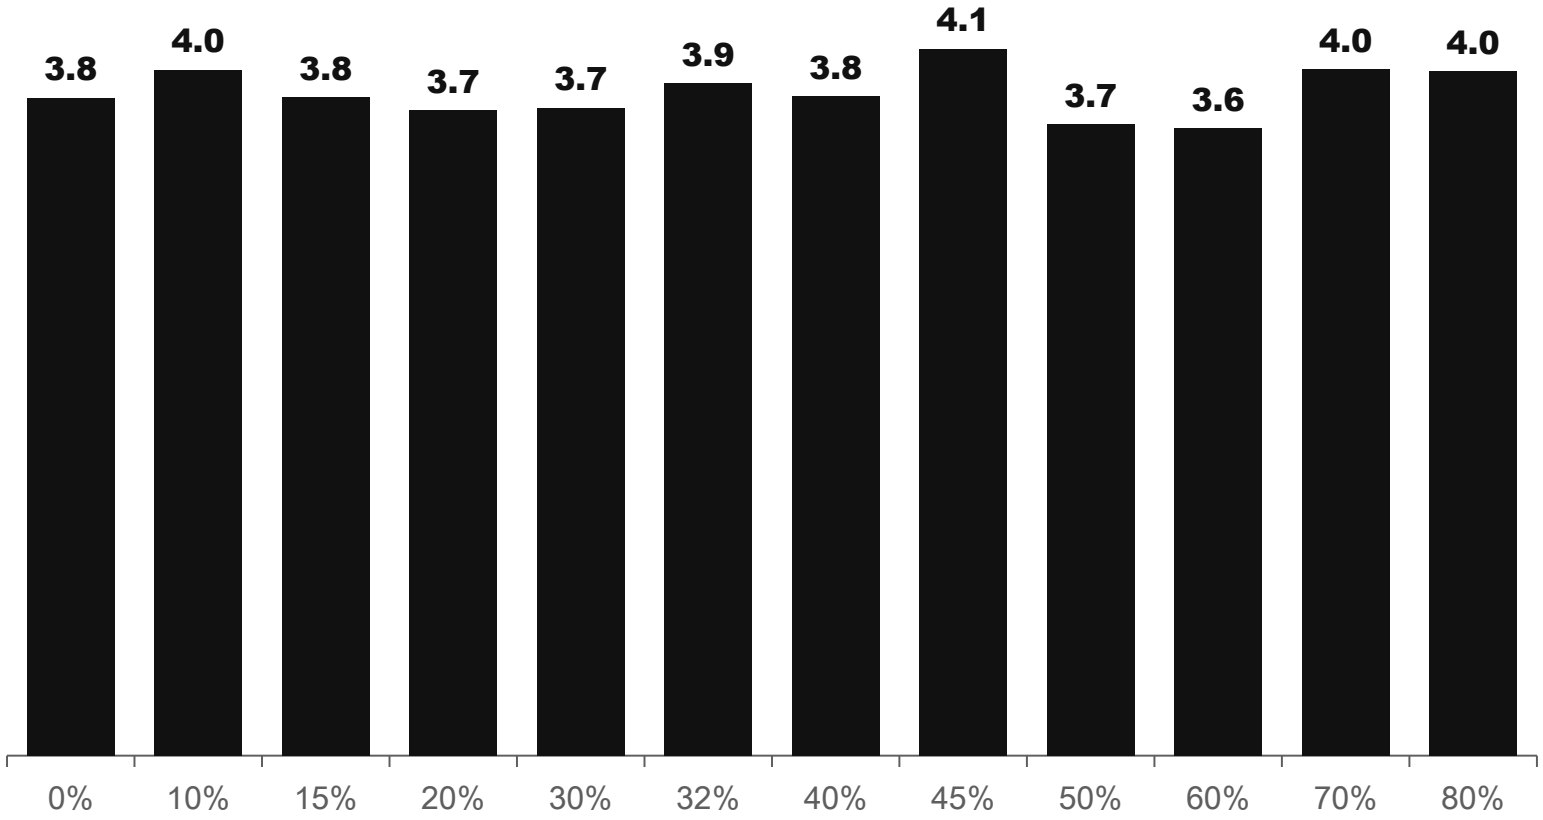
# Arriba de 20% de descuento casi todas las líneas pierden dinero




Proporción de líneas con pérdida por nivel de descuento, 2014 a 2017. Eje horizontal, descuento aplicado

INSIGHT 2 · H2 REFUTADA

# El descuento no compra volumen, el cliente lleva lo mismo con 0% que con 80%




**CORRELACIÓN DE SPEARMAN**

**rho = -0.001**

p = 0.94, Kruskal-Wallis p = 0.53

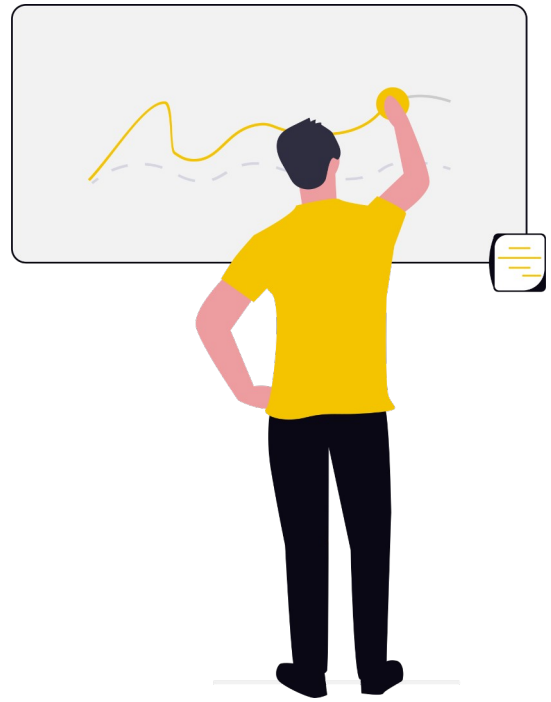
Quitar descuento donde genera pérdida tiene poco riesgo de perder ventas. Es la objeción principal a los topes y los datos no la sostienen.

Unidades promedio por línea según nivel de descuento, 2014 a 2017

# El gradient boosting supera a la regla de negocio en F1 y PR-AUC

Sin utilidad, margen ni costo para evitar fuga. Entrenamiento 2014 a 2016, prueba 2017. Hiperparámetros y umbral con validación cruzada temporal.

| Modelo | PR-AUC | F1 | Precisión | Recall | Pérdida detectada |
|---|---|---|---|---|---|
| Regla descuento mayor a 20% | 0.814 | 0.826 | 0.976 | 0.716 | 89% |
| Regresión logística | 0.945 | 0.841 | 0.846 | 0.835 | 94% |
| Árbol de decisión | 0.944 | 0.859 | 0.919 | 0.806 | 92% |
| Random forest | 0.957 | 0.864 | 0.814 | 0.919 | 98% |
| **Gradient boosting, elegido** | **0.967** | **0.889** | **0.905** | **0.874** | **96%** |
| Regla con costo histórico, sin ML | 0.997 | 0.995 | 0.995 | 0.995 | 100% |



IC 95% de F1 por bootstrap. Modelo 0.871 a 0.906, regla 0.802 a 0.851. La última fila es referencia, usa el costo del producto

INSIGHT 3 · H8 CONFIRMADA

# El modelo encuentra las pérdidas que la regla no ve con 20% de descuento

**169**

pérdidas en 2017 con exactamente 20% de descuento, de 1,223 líneas

**0**

detectadas por la regla de negocio

**94**

detectadas por el modelo, con 45 falsas alarmas

Importancia por permutación. Descuento 0.74, subcategoría 0.09, precio 0.04. Región, segmento y envío no aportan, la pérdida depende del producto y del descuento.

Fuente. reports/metrics/loss_model.json, prueba 2017

# Dónde falla el modelo, qué tan firme es y cuándo no hace falta

### DÓNDE SE EQUIVOCA

**78**

pérdidas no detectadas, el 96% con 20% de descuento. Suman el 3.7% del monto perdido. Las 57 falsas alarmas tenían $1,146 de utilidad.

### QUÉ TAN FIRME ES

**0.884 a 0.890**

F1 si el umbral se mueve 0.10. Intervalo bootstrap de 0.871 a 0.906. Los mismos números en cada corrida, una prueba automática lo exige.

### CUÁNDO NO HACE FALTA

**0.995**

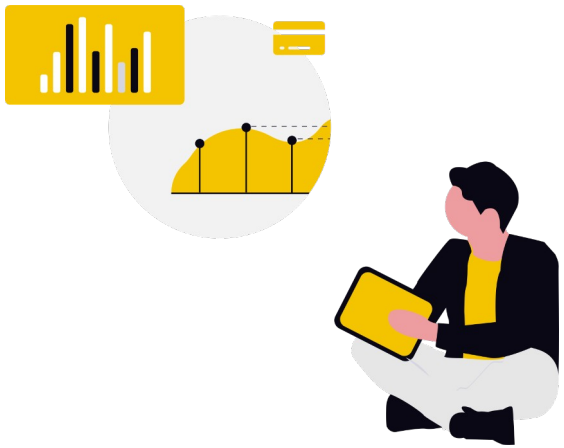
F1 de una regla con el costo histórico de cada producto, sin ML. El 97% de las líneas de 2017 tiene historial. Si el sistema expone el costo, se usa la regla.

**Lectura.** El modelo sirve donde no hay costo, como segundo método para fijar topes y para confirmar sin costo que la pérdida depende del descuento y la subcategoría. La decisión no depende del clasificador.

Errores y sensibilidad en reports/metrics/loss_model.json, prueba 2017

# Ocho subcategorías concentran la utilidad que se recupera con topes

| Subcategoría | Desc. promedio | Desc. máximo | Líneas con pérdida | Tope | Recupera 2017 |
|---|---|---|---|---|---|
| Binders | 37% | 80% | 40% | **30%** | $26,078 |
| Tables | 26% | 50% | 63% | **10%** | $17,035 |
| Machines | 31% | 70% | 40% | **25%** | $11,570 |
| Chairs | 17% | 30% | 36% | **10%** | $9,929 |
| Bookcases | 21% | 70% | 47% | **5%** | $6,510 |
| Storage | 7% | 20% | 19% | **0%** | $5,030 |
| Phones | 15% | 40% | 14% | **25%** | $3,643 |
| Appliances | 16% | 80% | 13% | **25%** | $2,804 |



Tope = menor entre el percentil 10 del descuento de equilibrio y el tope del modelo. Calculado solo con 2014 a 2016

# Con topes, la utilidad de 2017 casi se duplica y conviene aun perdiendo volumen

**Utilidad 2017**

$93K → **$183K**

**Líneas con pérdida**

620 → **49**

El tope cambia 925 líneas, el 28% del año.

**Sensibilidad a pérdida de volumen**

| Volumen perdido en líneas afectadas | Utilidad extra |
|---|---|
| 0% | +$89,220 |
| 10% | +$84,904 |
| 25% | +$78,430 |
| 50% | +$67,639 |
| **100%** | **+$46,058** |

Las líneas afectadas perdían $46,058 en conjunto. Aun perdiéndolas todas, la política conviene.

Utilidad recalculada con el costo unitario real de cada producto. Supuesto principal, volumen constante

CÓMO SE USA EL MODELO

# El modelo calcula, la regla recomienda y una persona decide

1 · SCORE

## Probabilidad de pérdida

El gradient boosting la calcula al capturar el pedido

2 · REGLA

## Semáforo auditable

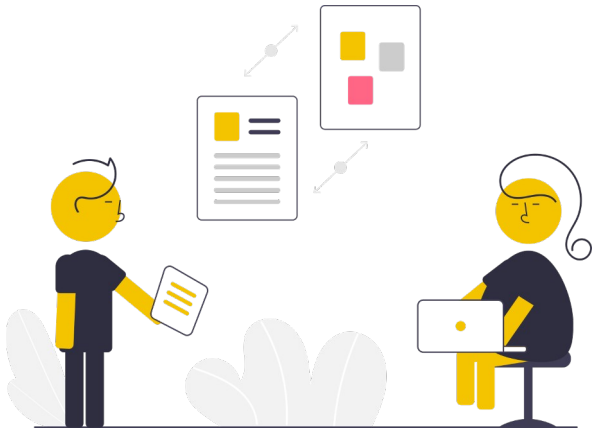
Rojo si supera el tope. Amarillo si el score pasa 0.45. Verde en otro caso

3 · DECISIÓN HUMANA

## Gerente comercial

Ajusta, aprueba una excepción con justificación o rechaza. Queda en bitácora

| Semáforo 2017 | Líneas | Por mes | Tasa de pérdida | Monto perdido |
|---|---|---|---|---|
| **Rojo** | 925 | 77 | 65% | 99.2% |
| **Amarillo** | 4 | 0 | 75% | 0.1% |
| **Verde** | 2,383 | 199 | 1% | 0.7% |



Revisión humana en 28% de las líneas, unas 77 al mes, que cubren el 99.3% del monto perdido

INSIGHT 4 · H5 Y H6 REFUTADAS

# El retraso no se puede predecir, el problema está en la promesa

**0 de 24**

pruebas chi-cuadrada significativas con Bonferroni. AUC de 0.46 a 0.52 dentro de cada modalidad

Tampoco explica el abandono. Los clientes inactivos tuvieron menos retrasos (28%) que los activos (33%). Mejorar envíos no recupera clientes.



| Modalidad | Promesa hoy | Cumple hoy | Promesa nueva | Cumpliría |
|---|---|---|---|---|
| Same Day | 0 días | 95% | 0 días | 95% |
| First Class | 2 días | 60% | 3 días | 100% |
| **Second Class** | **3 días** | **59%** | **5 días** | **100%** |
| Standard Class | 5 días | 70% | 7 días | 100% |

Second Class tarda 4 o 5 días el 41% de las veces, lo que hoy se espera de Standard Class. Para poder predecir después hay que registrar transportista, almacén y fecha real de entrega.

Promesa nueva = percentil 95 de días de envío por modalidad. Promesa actual es un supuesto del equipo

INSIGHT 5 · H7 REFUTADA

# Vender mucho no es ser rentable, cuatro grupos y uno destruye margen

## Alto valor rentable

**347**
clientes

Margen 18.4%
Descuento 12.4%
65% de las ventas
29% de las pérdidas

## Cazadores de descuento

**201**
clientes

Margen -5.4%
Descuento 24.4%
23% de las ventas
62% de las pérdidas

## Compradores ocasionales

**172**
clientes

Margen 21.0%
Descuento 10.0%
8% de las ventas
2% de las pérdidas

## Inactivos

**73**
clientes

Margen -0.2%
Descuento 21.6%
4% de las ventas
7% de las pérdidas

K-Means sobre recencia, frecuencia, monto, margen y descuento. k = 4, silueta 0.22, ARI bootstrap 0.72

SÍNTESIS

# Seis insights, cada uno con su acción

### La pérdida es una política

Reescribir la tabla de descuentos de 10 estados

### El descuento no compra volumen

Aplicar topes con un piloto que mida el efecto real

### Vender mucho no es ser rentable

Ofrecer servicio y no precio a los Cazadores

### El modelo ve la zona gris del 20%

Usarlo donde no hay costo del producto

### El retraso es un problema de promesa

Prometer 3, 5 y 7 días y registrar entregas

### La segmentación oficial no sirve

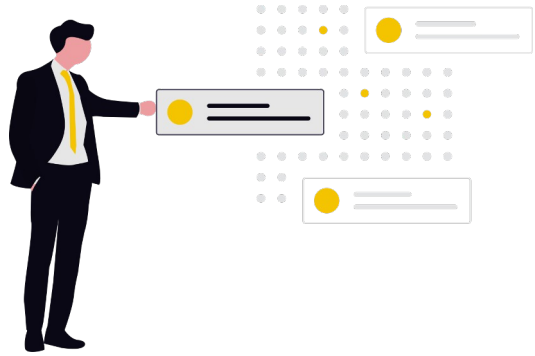
Presupuestar marketing con los cuatro grupos

Cada insight sale de una hipótesis probada o de un modelo evaluado contra línea base

# Evaluamos tres opciones y recomendamos la C

| Opción | Utilidad 2017 simulada | Riesgo |
|---|---|---|
| A. Mantener la política actual | $93,439 | Sigue perdiendo dinero en 10 estados |
| B. Topes en todo el país de inmediato | $182,660 | No mide el efecto real en volumen antes de escalar |
| **C. Topes en los 10 estados en dos olas, el resto después** | **$174,880** | **Bajo. La primera ola sirve de experimento contra la segunda** |

**Por qué C y no B.** Captura el 91% del beneficio con 815 de las 925 líneas afectadas, y mide el efecto real en volumen antes de escalar. Mientras corre la primera ola, la segunda funciona como grupo de control. Es reversible porque solo cambia una tabla.



Utilidad simulada con el costo real de 2017 y volumen constante

DECISIÓN

# Topes de descuento en los 10 estados de descuento alto, en dos olas, a partir del siguiente trimestre

**Semanas 1 a 2**

Finanzas aprueba la tabla y se carga en el sistema

**Semanas 3 a 8**

Ola 1 en cinco estados, los otros cinco de control

**Semanas 9 a 14**

Ola 2 en los cinco restantes

**Semana 15**

Dirección revisa y decide extender al país

## Criterios de éxito

Líneas con pérdida menores a 5% en estados tratados. Pedidos por cliente sin caer más de 10% contra control. Margen positivo en los 10 estados.

## Criterio de alto

Si los pedidos por cliente caen más de 25% contra el control, se revisan los topes antes de la segunda ola. En paralelo, nueva promesa de entrega y campañas por grupo.

# La solución vive como producto de BI con modelos integrados




| Monitoreo | Regla |
|---|---|
| **Reentrenamiento** | Cada trimestre con datos nuevos, recalculando los topes |
| **Deriva** | Vigilar la distribución del descuento y del precio de lista |
| **Alerta de negocio** | Líneas con pérdida mayores a 5% en cualquier estado |
| **Alerta de modelo** | F1 del trimestre por debajo del de la regla simple |

El modelo estrella se conecta igual a Power BI, Looker Studio o Tableau. data/processed/bi

# Los límites están acotados y todo se regenera con un comando

**Datos sintéticos.** La utilidad sale de una fórmula con costo fijo. Con fletes y devoluciones las métricas bajarían.

**El costo explica la pérdida.** Con el costo del producto una regla llega a F1 0.995, el modelo no es indispensable.

**Volumen por línea.** No vemos a quien no compró, por eso el piloto con grupo de control.

**Promesa supuesta.** La recomendación usa la distribución real de días, no la tasa.

**Grupos con frontera difusa.** Silueta 0.22, los perfiles son tendencias.

**Un país, cuatro años.** No se valida en otro mercado.

**Se regenera en 35 segundos**

```
uv sync

uv run python src/run_all.py

uv run pytest -q
```

Versiones fijas en uv.lock y una prueba que exige los mismos números en cada corrida. El notebook corre en Google Colab.

Detalle en la sección 3.2 del reporte técnico

ROLULABO

# Preguntas

Menos descuento donde no se paga, una promesa de entrega honesta y una estrategia distinta para cada grupo de clientes.

**Elaborado por Gabriel Álvarez Mendoza**



Herramientas e IA. Python, scikit-learn y uv. Claude (Anthropic) como asistente para código, revisión metodológica y borradores. Las decisiones, la ejecución y la interpretación son del equipo, y las verificaciones están en la Declaración de herramientas. Datos, Sample Superstore, Kaggle.