

UNIVERSIDAD
Panamericana

Facultad de Ingeniería

Materia: Aprendizaje de Máquina

Alumnos: Gabriel Álvarez Mendoza - 0261445
Eduardo Gutiérrez
Emiliano Luna
Rodrigo Naranjo Hernández - 0250016

Nombre de actividad: Proyecto Rolulabo

Fecha de entrega: 09/11/2026

Índice

Portada
Resumen ejecutivo
1 Introducción
- 1.1 Background
- 1.2 Problema y punto principal
- 1.3 Propósito del reporte
- 1.4 Audiencia objetivo
- 1.5 Relación con los Objetivos de Desarrollo Sostenible

2 Revisión de fuentes de información
3 Alcance
- 3.1 Supuestos básicos
- 3.2 Limitaciones del reporte
- 3.3 Tópicos cubiertos y no cubiertos

4 Criterio
- 4.1 Criterio para juzgar los resultados
- 4.2 Criterio para llegar a las recomendaciones

5 Metodología
- 5.1 CRISP-DM con iteraciones ágiles
- 5.2 Backlog en historias de usuario
- 5.3 Iteraciones

6 Comprensión del negocio
- 6.1 KPIs y metas
- 6.2 Preguntas analíticas y decisiones

7 Datos recogidos y preparación
- 7.1 Fuente
- 7.2 Exploración
- 7.3 Validaciones
- 7.4 Hallazgo estructural
- 7.5 Variables derivadas
- 7.6 Modelo estrella para BI
- 7.7 Valores atípicos y sesgos

8 Hipótesis iniciales
9 Modelado y evaluación
- 9.1 Líneas con pérdida
- 9.2 Entregas fuera de tiempo
- 9.3 Segmentación de clientes

10 Insights
11 Decisión de negocio
12 Score, regla y decisión humana
13 Despliegue, BI y monitoreo
14 Conclusiones
15 Recomendaciones
16 Reproducibilidad y uso de inteligencia artificial
- 16.1 Reproducibilidad
- 16.2 Declaración de uso de inteligencia artificial

17 Referencias

Resumen ejecutivo

Decisión recomendada. Aplicar topes de descuento por subcategoría en los 10 estados de descuento alto a partir del siguiente trimestre, en dos olas de cinco estados que funcionan como experimento controlado, y extenderlos al resto del país solo si se cumplen los criterios de éxito. Con datos de 2017, esa decisión lleva a los 10 estados de -$36,671 a $44,770 de utilidad y captura el 91% del beneficio total posible.

Rolulabo vendió $2,296,919 entre 2014 y 2017 con una utilidad de $286,409, un margen de 12.5%. El 18.7% de las líneas de venta cerró con pérdida y esas líneas restaron $156,119, el 35% de lo que ganaron las líneas rentables.

Antes de modelar escribimos ocho creencias del negocio y las probamos con datos. 7 resultaron refutadas. Las tres más importantes cambiaron el proyecto.

- **El descuento no lo decide el vendedor.** Es una tabla fija por estado y subcategoría, y en 10 estados supera el margen del producto. Ahí se concentra el 93% de las pérdidas con 39% de las líneas.
- **El descuento no compra volumen.** La cantidad por línea es la misma con 0% que con 80% de descuento (rho = -0.001). Quitar descuento donde pierde dinero tiene poco riesgo comercial.
- **Vender mucho no es ser rentable.** El grupo Cazadores de descuento compra casi tan seguido como el de mayor valor, pero su margen es negativo y genera el 62% de las pérdidas.

Tres modelos sostienen la decisión. Un gradient boosting detecta las líneas que van a perder dinero con F1 de 0.889 contra 0.826 de la regla actual. Un análisis de entregas demuestra que el retraso no se puede predecir con los datos disponibles, así que el ajuste es en la promesa. Un K-Means separa cuatro grupos de clientes con estrategias distintas.

Un hallazgo acota el papel del clasificador. Como la pérdida depende del costo de cada producto, una regla sin aprendizaje de máquina que usa el costo histórico llega a F1 de 0.995. Cuando el sistema conoce el costo, esa regla es la mejor herramienta para detectar pérdidas. El modelo aporta donde no hay costo y como segundo método para fijar los topes. La decisión recomendada no depende del clasificador.

Ningún modelo decide solo. Cada resultado sigue el esquema score, regla y decisión. El modelo calcula un score, una regla explícita lo convierte en recomendación y una persona con nombre de puesto acepta, ajusta o rechaza. En 2017 el semáforo habría mandado a revisión humana 28% de las líneas, unas 77 al mes, que concentran el 99.3% del monto perdido.

1 Introducción

1.1 Background

Rolulabo es una cadena ficticia de artículos de oficina, muebles y tecnología que vende en 49 estados de Estados Unidos a tres segmentos de cliente, consumidores, empresas y oficinas en casa. Entre 2014 y 2017 sus ventas crecieron 52%, pero el margen se estancó alrededor de 13% desde 2015 y casi una de cada cinco líneas de venta cerró con pérdida. La empresa ofrece descuentos como principal palanca comercial, envía por cuatro modalidades con distinto tiempo de entrega y administra a sus 793 clientes como un solo bloque.

El proyecto toma el caso como lo haría un equipo de BI con aprendizaje de máquina dentro de la empresa. Parte de una necesidad de negocio, formula preguntas analíticas, prepara los datos, entrena y evalúa modelos contra una línea base, y termina en una decisión con dueño, plan y criterios para saber si funcionó.

1.2 Problema y punto principal

La empresa observa que una proporción relevante de sus líneas de venta cierra con margen negativo por una política de descuentos definida por estado y subcategoría sin relación con el costo del producto, que sus pedidos incumplen con frecuencia los tiempos de entrega prometidos, y que no distingue entre perfiles de cliente al definir su política comercial. Esto provoca que el crecimiento en ventas no se traduzca en mejor margen, que las pérdidas se detecten hasta el cierre contable, y que el esfuerzo comercial y los descuentos se concentren en clientes que destruyen margen.

El punto principal del reporte es que el problema no está en los vendedores ni en la logística, sino en una tabla de descuentos. El descuento es fijo por estado y subcategoría, y en 10 estados supera el margen del producto. Los modelos ayudan a encontrarlo, a medirlo y a vigilar una nueva política, pero la decisión de cambiarla es humana.

1.3 Propósito del reporte

El objetivo es reducir la proporción de líneas con margen negativo y elevar la utilidad por transacción, de modo que el área comercial siga usando el descuento como palanca de venta, ahora con topes por subcategoría basados en evidencia y con políticas diferenciadas por tipo de cliente. En paralelo, que la promesa de entrega refleje los tiempos reales de cada modalidad.

El reporte busca tres cosas. Responder con evidencia tres preguntas analíticas sobre pérdidas, entregas y clientes. Probar las creencias que el negocio daba por ciertas antes de construir sobre ellas. Y traducir los resultados en una decisión concreta, con opciones, impacto, responsables y criterios de éxito.

1.4 Audiencia objetivo

El documento está dirigido al profesor y al grupo de Aprendizaje de Máquina, que conocen las técnicas de clasificación, validación y clustering. Al mismo tiempo está escrito como lo leería la dirección de Rolulabo. El resumen ejecutivo, los insights, la decisión y las recomendaciones se pueden leer sin conocimientos técnicos. Las secciones de metodología, datos y modelado documentan el detalle para quien quiera reproducir o auditar el trabajo.

1.5 Relación con los Objetivos de Desarrollo Sostenible

El proyecto se relaciona con el ODS 8, Trabajo decente y crecimiento económico, en particular con la meta 8.2, que busca elevar la productividad económica mediante la modernización tecnológica y la innovación. La relación es concreta pero indirecta. El análisis eleva la utilidad por transacción de la empresa con el mismo volumen de venta, usando datos que ya tiene, y una empresa más productiva sostiene mejor su operación y sus

empleos. No se vincula con ODS ambientales, como el 12, porque los datos no traen información de consumo de recursos o residuos que permita sostener esa relación.

2 Revisión de fuentes de información

La fuente de datos es la versión completa del dataset Sample Superstore publicada en Kaggle, que incluye descuento, cantidad y utilidad por línea. Es un dataset sintético y público, usado ampliamente para enseñanza, lo que garantiza que no contiene información personal real.

La metodología se apoya en cinco referencias. La guía CRISP-DM 1.0 de Chapman y colaboradores define las fases del proyecto. El Scrum Guide de Schwaber y Sutherland da el marco de iteraciones y backlog. The Data Warehouse Toolkit de Kimball y Ross sustenta el modelo estrella de la capa de BI. El artículo de Saito y Rehmsmeier justifica usar PR-AUC en lugar de ROC-AUC con clases desbalanceadas, y el de Rousseeuw define el coeficiente de silueta usado para evaluar los grupos. La implementación usa scikit-learn, documentado por Pedregosa y colaboradores.

Conviene señalar el límite de este conjunto. Los datos describen un negocio simulado, por lo que las cifras sirven para demostrar el método y no como medición de una empresa real. Las referencias metodológicas son estándares de la práctica y no estudios sobre el caso.

3 Alcance

3.1 Supuestos básicos

El trabajo parte de cuatro supuestos. El primero es que el costo unitario implícito en los datos es el costo contable del producto, lo que permite calcular el descuento de equilibrio y simular la utilidad con otro descuento. El segundo es que la cantidad vendida no cambia cuando se reduce el descuento, supuesto que se prueba con la hipótesis H2 y se cubre con escenarios de pérdida de volumen. El tercero es una promesa de entrega por modalidad de 0, 2, 3 y 5 días, porque el dataset no la trae. El cuarto es que 2014 a 2016 representan bien lo que pasará en 2017, lo que se verifica con la partición temporal.

3.2 Limitaciones del reporte

- **Datos sintéticos.** La utilidad sale de una fórmula con costo fijo por producto. En datos reales habría fletes, devoluciones y cambios de costo, y las métricas del modelo serían menores. El método se puede trasladar, el nivel de desempeño no.
- **El costo explica la pérdida.** Con el costo de cada producto una regla sin aprendizaje de máquina llega a F1 de 0.995. El clasificador no es indispensable cuando el costo está en el sistema, y así se reporta.
- **Sensibilidad al entorno.** Con otras versiones de scikit-learn el umbral óptimo cambia aunque el F1 no. Las versiones quedan fijas en uv.lock y una prueba automática verifica que los números de referencia se reproduzcan.
- **Volumen observado solo por línea.** H2 muestra que la cantidad por línea no depende del descuento, pero el dataset no registra a los clientes que no compraron. Por eso la decisión incluye un piloto con grupo de control.
- **Promesa de entrega supuesta.** La tasa de retraso depende de la promesa definida. La recomendación se basa en la distribución real de días, no en la tasa.
- **Topes por subcategoría.** Dentro de una subcategoría hay productos con márgenes muy distintos. Un tope por producto, que el dashboard ya muestra, es más preciso pero más difícil de operar.

- **Separación moderada de grupos.** La silueta de 0.22 indica clientes en la frontera entre grupos. Los perfiles describen tendencias, no categorías rígidas.
- **Un solo país y cuatro años.** No se puede validar el modelo en otro mercado ni capturar cambios de largo plazo.

3.3 Tópicos cubiertos y no cubiertos

Se cubren la rentabilidad por línea de venta, la política de descuentos y su rediseño, el cumplimiento de la promesa de entrega, la segmentación de clientes por valor y rentabilidad, la lectura cruzada de los tres análisis, el esquema de decisión humana y el despliegue como producto de BI. Quedan fuera el pronóstico de demanda e inventario, la estimación formal de elasticidad precio, la optimización de rutas logísticas, los costos operativos distintos al costo del producto y cualquier tema de personal, porque el dataset no tiene información para sostenerlos.

4 Criterio

4.1 Criterio para juzgar los resultados

Cada resultado se juzga contra una línea base y en datos que el modelo no vio. En clasificación de pérdidas la métrica principal es PR-AUC, porque las clases están desbalanceadas, acompañada de F1, precisión y recall con intervalos de confianza por bootstrap. Un modelo solo se acepta si supera a la regla de negocio que ya existe, no solo al azar. En entregas el criterio de aceptación es un AUC mayor a 0.65 y pruebas estadísticas con corrección por comparaciones múltiples. En segmentación se exige estabilidad entre semillas y en remuestreo, medida con el índice de Rand ajustado, además de silueta y Davies-Bouldin. Para el negocio, el criterio final es la utilidad simulada y los KPIs de la sección 6.

4.2 Criterio para llegar a las recomendaciones

Las recomendaciones se formulan bajo cinco condiciones. Deben poder aplicarse con los datos y sistemas que la empresa ya tiene. Deben ser medibles y reversibles. Deben tener un responsable humano con nombre de puesto que tome la decisión y deje registro. Deben sostenerse aun bajo los escenarios pesimistas del análisis de sensibilidad. Y deben cuantificar su impacto esperado en utilidad o en un KPI.

5 Metodología

5.1 CRISP-DM con iteraciones ágiles

El proyecto sigue CRISP-DM, el estándar de la industria para proyectos de minería de datos, organizado en tres iteraciones cortas al estilo ágil. Cada iteración cierra con un entregable que funciona y con la revisión de las hipótesis. Si una hipótesis cae, el backlog se ajusta antes de la siguiente iteración.

Fase CRISP-DM	Pregunta que responde	Entregable	Dónde vive
Comprensión del negocio	Qué decisión hay que apoyar y cómo se mide el éxito	Planteamiento, KPIs, historias de usuario	Secciones 1 y 6
Comprensión de los datos	Qué datos hay y qué creencias del negocio sostienen o no	EDA y prueba de 8 hipótesis	src/hypotheses.py
Preparación de datos	Los datos son confiables y están listos para modelar y para BI	ETL validado y modelo estrella	src/etl.py
Modelado	Qué técnica responde cada pregunta analítica	Tres modelos con validación temporal	src/loss_model.py y otros
Evaluación	El modelo supera a la línea base y qué vale para el negocio	Métricas, intervalos y simulación de política	reports/metrics
Despliegue	Cómo llega el resultado a quien decide	Score, regla y decisión humana, dashboard y monitoreo	app/dashboard.py

5.2 Backlog en historias de usuario

Cada pregunta analítica nace de una necesidad de un área. El criterio de aceptación dice cuándo la historia está terminada.

Historia	Criterio de aceptación	Estado
Como gerente comercial quiero saber antes de cerrar si una línea va a perder dinero, para ajustar el descuento	Modelo mejor que la regla actual en F1, con intervalo de confianza	Terminada
Como director de finanzas quiero un tope de descuento por subcategoría con su impacto en utilidad, para aprobar una nueva política	Topes calculados sin usar 2017 y simulados sobre 2017	Terminada
Como gerente de operaciones quiero saber qué pedidos llegarán tarde, para priorizarlos	AUC mayor a 0.65 en 2017	Replanteada. El AUC fue 0.5, se entrega promesa realista
Como gerente de marketing quiero grupos de clientes con su rentabilidad, para asignar presupuesto	Grupos estables y con perfil accionable	Terminada
Como director general quiero una sola lectura de las causas, para decidir dónde actuar	Decisión con opciones, impacto y criterios de éxito	Terminada

5.3 Iteraciones

Iteración	Fases	Entregable	Qué cambió al cerrar
1. Negocio y datos	Negocio, datos, preparación	ETL validado, EDA, hipótesis probadas	H1 cayó. El problema pasó de capacitar vendedores a corregir una tabla de descuentos
2. Modelos	Modelado, evaluación	Tres modelos contra línea base	H5 cayó. La historia de Operaciones se replanteó como ajuste de promesa
3. Decisión y despliegue	Evaluación, despliegue	Simulación, dashboard, decisión	H2 cayó. El riesgo de perder volumen con topes resultó bajo

Definición de terminado para cualquier entregable. Se regenera con un comando desde el CSV crudo, se compara contra una línea base y está ligado a una decisión de un área.

6 Comprensión del negocio

6.1 KPIs y metas

La utilidad se descompone en ventas por margen, y el margen de cada línea depende de la distancia entre el descuento aplicado y el descuento de equilibrio del producto. De ahí salen los KPIs que el dashboard sigue.

KPI	Línea base	Meta a un año	Dueño
Líneas con pérdida	18.7%	Menos de 5%	Finanzas
Margen neto	12.7% en 2017	Más de 20% (simulado 22.2%)	Dirección
Cumplimiento de promesa de entrega	67.5%	Más de 95%	Operaciones
Utilidad del grupo Cazadores de descuento	-16% del total	Positiva	Marketing

6.2 Preguntas analíticas y decisiones

1. Con la información disponible al capturar un pedido, se puede anticipar si una línea cerrará con pérdida, y hasta qué descuento sigue siendo rentable cada subcategoría?
2. Se puede anticipar qué pedidos excederán el tiempo de entrega prometido por su modalidad?
3. Existen grupos de clientes con comportamiento de compra y rentabilidad distintos que justifiquen políticas diferenciadas?

Área	Recibe	Decide
Comercial	Evaluador de línea y tabla de topes	Autorizar o ajustar el descuento antes de cerrar
Finanzas	Simulación de la política de topes	Aprobar la nueva tabla de descuentos por estado
Operaciones	Tiempos reales por modalidad	Redefinir la promesa de entrega
Marketing	Cuatro grupos de clientes con perfil	Asignar presupuesto y campañas por grupo
Dirección	Lectura cruzada y opciones	Atacar el problema con precio, logística o mezcla de clientes

7 Datos recogidos y preparación

7.1 Fuente

Se usó la versión completa del dataset Sample Superstore publicada en Kaggle por Vivek Chowdhury, que incluye descuento, cantidad y utilidad. Contiene 9,994 líneas de pedido y 21 columnas de una cadena de artículos de oficina en Estados Unidos, del 3 de enero de 2014 al 30 de diciembre de 2017. Abarca 5,009 pedidos, 793 clientes, 49 estados, 17 subcategorías y 3 categorías. Los datos son sintéticos y públicos, sin información personal sensible más allá de nombres ficticios de clientes, que no se usan en ningún modelo.

7.2 Exploración

La utilidad no crece con el descuento, se destruye. Con 0% de descuento ninguna línea pierde dinero. Con 20% pierde el 14%. Con 30% o más pierden entre 87% y 100%.

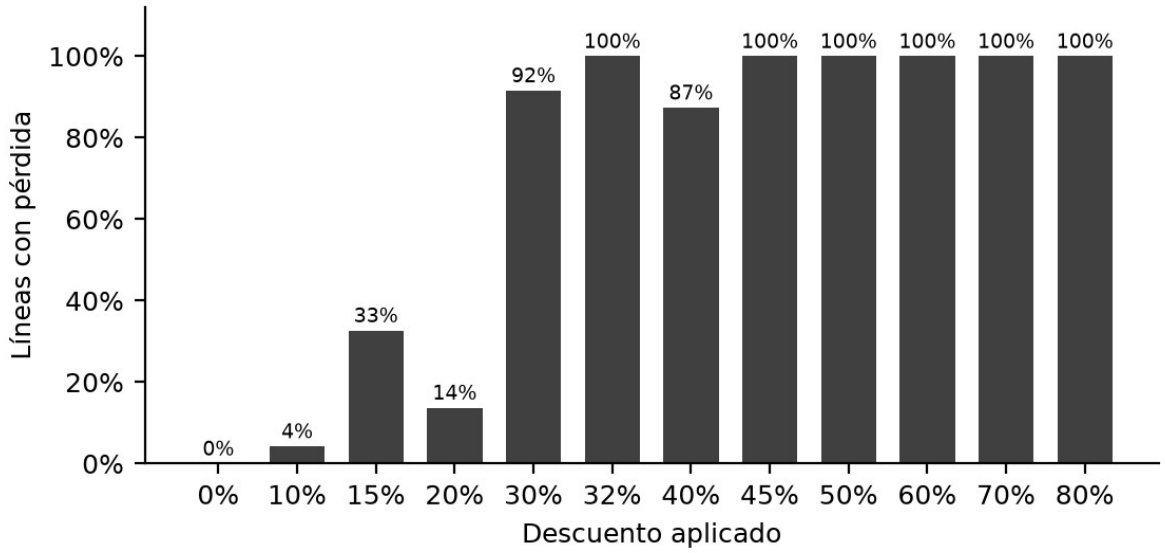


Figura 1. Proporción de líneas con pérdida por nivel de descuento, 2014 a 2017.

Tres subcategorías tienen utilidad acumulada negativa en 2014 a 2016, Tables, Bookcases y Supplies. Binders y Machines son rentables en total pero tienen 40% de líneas con pérdida, porque reciben descuentos de hasta 70% y 80% en los estados de descuento alto. Texas, Ohio, Pennsylvania e Illinois son los cuatro estados con mayor pérdida acumulada. En entregas, cada modalidad tiene un rango de días bien definido. Same Day entrega en 0 o 1 días, First Class de 1 a 4, Second Class de 1 a 5 y Standard Class de 3 a 7.

7.3 Validaciones

Todas las validaciones se ejecutan en src/etl.py y su resultado queda en reports/metrics/data_quality.json.

Validación	Resultado	Decisión
Esquema de 21 columnas	Correcto	Ninguna
Valores nulos	0	Ninguna
Duplicados exactos sin Row ID	1	Se elimina, filas 3406 y 3407 idénticas
Envío antes del pedido	0	Ninguna
Ventas o cantidad no positivas	0	Ninguna
Descuento fuera de 0 a 1	0	Ninguna
Pedidos con más de una fecha, modalidad o cliente	0	El pedido es unidad válida
Product ID usado para dos productos	32	Llave de producto es ID más nombre
Costo unitario no constante por producto	0	Se puede simular utilidad exacta

7.4 Hallazgo estructural

La pérdida es determinista. El costo unitario es constante por producto. Por eso una línea pierde dinero exactamente cuando el descuento supera el descuento de equilibrio, igual a 1 menos costo entre precio de lista. Esta regla explica el 100% de las pérdidas. Permite simular con exactitud la utilidad bajo otro descuento, y obliga a reconocer que las métricas del modelo serán altas porque los datos son sintéticos (sección 3.2).

7.5 Variables derivadas

Variable	Definición	Uso
list_price	ventas entre cantidad entre (1 menos descuento)	Modelo y simulación
unit_cost	(ventas menos utilidad) entre cantidad	Solo simulación y topes
breakeven_discount	1 menos costo entre precio de lista	Solo topes
is_loss	1 si la utilidad es negativa	Objetivo del modelo 1
days_to_ship	fecha de envío menos fecha de pedido	Análisis de entregas
is_late	1 si días de envío superan la promesa	Objetivo del análisis 2
RFM y margen	recencia, frecuencia, monto, margen y descuento por cliente	Segmentación

7.6 Modelo estrella para BI

Además de las tablas analíticas, el ETL publica un modelo estrella en data/processed/bi, listo para conectarse a Power BI, Looker Studio o Tableau. La tabla de hechos fact_lineas tiene 9,993 filas y se une a cuatro dimensiones con llaves sustitutas, dim_cliente (793), dim_producto (1,894), dim_geografia (632) y dim_fecha (1,464 días). El ETL verifica que los joins no pierdan filas.

7.7 Valores atípicos y sesgos

Atípicos. Se midieron con la regla de Tukey, valores fuera de 1.5 veces el rango intercuartílico. Son ventas reales y no errores de captura, así que no se eliminan. El 1% de las líneas con mayor venta concentra el 20% de las ventas. El tratamiento es de modelado. El precio entra en logaritmo, los modelos de árboles no dependen de la escala y en la segmentación el margen se recorta en los percentiles 1 y 99.

Variable	Atípicos	% de líneas	Mediana	Máximo
Venta por línea	1,167	11.7%	$54	$22,638
Precio de lista	1,025	10.3%	$20	$7,546
Cantidad	170	1.7%	3	14
Utilidad por línea	1,881	18.8%	$9	$8,400

Sesgos. Cuatro sesgos condicionan la lectura. El primero es de representatividad. West tiene 32% de las líneas y South 16%, y 2017 aporta 33% por el crecimiento, así que las métricas pesan más lo reciente y lo occidental. El segundo es de confusión. El descuento es fijo por estado y subcategoría, por lo que no se puede separar el efecto del estado del efecto del descuento. El tercero es de selección. Solo hay ventas cerradas, no cotizaciones perdidas, y por eso la elasticidad al precio no se puede estimar. El cuarto es que los datos son sintéticos y la utilidad sale de una fórmula con costo fijo.

8 Hipótesis iniciales

Las hipótesis se escribieron como el negocio las diría y se probaron antes de modelar. Una hipótesis refutada vale tanto como una confirmada, porque evita invertir en la solución equivocada. De ocho, 7 se refutaron y 1 se confirmó.

Cada hipótesis tiene un criterio de decisión escrito antes de ver el resultado, y el veredicto sale del estadístico, no de un texto fijo. El nivel de significancia es 0.05. H6 se prueba con una cola porque la creencia es direccional.

	Creencia del negocio	Prueba, criterio y evidencia	Resultado
H1	El descuento lo decide cada vendedor en cada venta	Valores distintos de descuento por combinación estado y subcategoría. Se refuta si al menos 95% de las combinaciones tiene un solo descuento. 656 de 656 combinaciones tienen un solo descuento	**Refutada**
H2	Dar más descuento hace que el cliente compre más unidades	Correlación de Spearman entre descuento y cantidad, y Kruskal-Wallis por nivel de descuento. Se refuta si la correlación no es significativa (alfa 0.05) o es menor a 0.10 en valor absoluto. rho = -0.001 (p = 0.94), Kruskal-Wallis p = 0.53. Cantidad promedio de 3.6 a 4.1 unidades en todos los niveles	**Refutada**
H3	Las pérdidas vienen de cierto tipo de cliente (Consumer, Corporate, Home Office)	Chi-cuadrada de independencia entre segmento y pérdida, con V de Cramér. Se refuta si la prueba no es significativa (alfa 0.05) o la V de Cramér es menor a 0.10. Pérdida de 17.5% a 19.3% por segmento, p = 0.19, V = 0.02. Por región va de 10% a 32% (V = 0.21)	**Refutada**
H4	Las pérdidas se concentran en el cuarto trimestre por promociones de temporada	Chi-cuadrada entre trimestre y pérdida. Se refuta si la prueba no es significativa (alfa 0.05). Pérdida de 17.5% a 19.3% por trimestre, p = 0.29	**Refutada**
H5	Los retrasos se concentran en ciertas regiones, categorías o meses	24 pruebas chi-cuadrada por modalidad con corrección de Bonferroni y modelos de clasificación. Se refuta si ninguna prueba es significativa con Bonferroni y ningún modelo llega a AUC 0.65 en 2017. 0 de 24 pruebas significativas, AUC de 0.46 a 0.52	**Refutada**
H6	Los clientes que dejaron de comprar se fueron por entregas tardías	Mann-Whitney de una cola, tasa de retraso de clientes inactivos (más de un año sin comprar) mayor que la de activos. Se refuta si la prueba de una cola no es significativa (alfa 0.05). Inactivos 28% de pedidos tarde contra 33% de los activos, en sentido contrario a la creencia (p = 0.98)	**Refutada**
H7	Los clientes que más compran son los más rentables	Correlación de Spearman entre ventas del cliente y su margen. Se refuta si la correlación no es positiva, significativa (alfa 0.05) y de al menos 0.10. Ventas contra margen rho = 0.04 (p = 0.29). Descuento contra margen rho = -0.59 (p < 0.001)	**Refutada**
H8	Un modelo de aprendizaje de máquina detecta pérdidas mejor que una regla de negocio simple	F1 y PR-AUC en 2017 con intervalos bootstrap de 95%. Se confirma si el intervalo de F1 del modelo queda completo por encima del de la regla actual. F1 0.889 contra 0.826, intervalos sin traslape. Detecta 94 de 169 pérdidas con 20% de descuento que la regla no ve	**Confirmada**

Qué cambió con cada refutación.

- **H1.** El descuento es una política regional. Se corrige cambiando una tabla, no capacitando vendedores.
- **H2.** El descuento no compra volumen. Quitarlo donde genera pérdida tiene poco riesgo de perder ventas.
- **H3.** La pérdida depende de dónde se vende y con qué descuento, no de quién compra.
- **H4.** No hay un problema estacional. La política de descuento pierde dinero todo el año.
- **H5.** Con los datos actuales no hay a quién priorizar. El ajuste es en la promesa.
- **H6.** El abandono no se explica por logística. Reactivar a los inactivos no pasa por mejorar envíos.
- **H7.** Vender mucho no es ser rentable. El margen del cliente lo decide el descuento que recibe.
- **H8.** El modelo supera a la regla actual. Pero si el sistema conoce el costo de cada producto, una regla de costo histórico llega a F1 0.995 sin aprendizaje de máquina.

9 Modelado y evaluación

9.1 Líneas con pérdida

Técnica. Clasificación binaria con desbalance moderado, 18.7% de positivos. Se compararon cuatro modelos de complejidad creciente, regresión logística, árbol de decisión, random forest y gradient boosting, contra tres líneas base. La proporción de la clase, la regla de negocio descuento mayor a 20% y una regla informada que usa el costo histórico de cada producto. La regla actual es la comparación relevante para el negocio, porque un modelo solo aporta si supera lo que ya se hace. La regla de costo es la referencia honesta de lo que se logra sin

aprendizaje de máquina cuando el costo existe. Los cuatro modelos van de menor a mayor complejidad. La regresión logística es lineal e interpretable, el árbol produce reglas legibles, y random forest y gradient boosting capturan la interacción entre descuento y subcategoría que explica la pérdida.

Variables. Descuento, subcategoría, categoría, región, segmento, modalidad de envío, cantidad, logaritmo del precio de lista y mes. Se excluyen utilidad, margen y costo unitario porque el vendedor no los conoce al capturar el pedido y su inclusión sería fuga de información.

Validación. Partición temporal, entrenamiento con 2014 a 2016 (6,681 líneas) y prueba con 2017 (3,312 líneas). Dentro de entrenamiento, validación cruzada de ventana creciente (2014 predice 2015, 2014 a 2015 predicen 2016) para elegir hiperparámetros y el umbral que maximiza F1, buscado en una rejilla de 0.05 para que sea estable. El modelo final se elige por PR-AUC de validación sin mirar la prueba. Intervalos de 95% por bootstrap con 1,000 remuestreos.

Modelo	ROC-AUC	PR-AUC	F1	Precisión	Recall	Pérdida detectada
Proporción de la clase	0.500	0.187	0.000	0.000	0.000	0%
Regla descuento > 20%	0.940	0.814	0.826	0.976	0.716	89.3%
Regresión logística	0.985	0.945	0.841	0.846	0.835	93.8%
Árbol de decisión	0.986	0.944	0.859	0.919	0.806	92.4%
Random forest	0.988	0.957	0.864	0.814	0.919	98.0%
Gradient boosting	0.991	0.967	0.889	0.905	0.874	96.3%
Regla costo histórico, referencia sin ML	0.999	0.997	0.995	0.995	0.995	99.9%

El gradient boosting (tasa de aprendizaje 0.05, profundidad 6, umbral 0.45) tuvo el mejor PR-AUC en validación (0.953) y en prueba (0.967), sin señales de sobreajuste. Su F1 es 0.889 con intervalo de 0.871 a 0.906, contra 0.802 a 0.851 de la regla. En 2017 detectó 542 pérdidas, dejó pasar 78 y dio 57 falsas alarmas.

Dónde aporta. La regla no ve las pérdidas con descuento de exactamente 20%. En 2017 hubo 1,223 líneas con ese descuento y 169 perdieron dinero. El modelo detecta 94 con 45 falsas alarmas, porque aprende que con 20% pierden Storage, Bookcases, Supplies y Tables pero no Paper, Binders ni Art. La importancia por permutación lo confirma. Descuento 0.74, subcategoría 0.09, precio 0.04, y región, segmento y envío cerca de cero.

Análisis de errores. En 2017 el modelo dejó pasar 78 pérdidas. El 96% tenía exactamente 20% de descuento, la zona donde el resultado depende del producto, y suman $1,986, el 3.7% del monto perdido. Son pérdidas chicas en subcategorías con margen cercano al equilibrio, sobre todo Accessories, Chairs, Phones. Las 57 falsas alarmas tenían $1,146 de utilidad, el costo de revisarlas es bajo frente a lo que se recupera.

Robustez del umbral. El F1 en prueba se mueve entre 0.884 y 0.890 si el umbral cambia 0.10 hacia arriba o hacia abajo. La conclusión no depende de un umbral exacto. Por eso se eligió en una rejilla de 0.05 y no como el máximo exacto de la curva, que brincaba entre 0.37 y 0.45 en distintos entornos de ejecución.

Línea base con costo. La pérdida es determinista, así que basta conocer el costo del producto para anticiparla. El 96.8% de las líneas de 2017 son de productos que ya se vendieron en 2014 a 2016, y para ellas la regla de costo histórico acierta en todos los casos. En toda la prueba llega a F1 de 0.995, contra 0.889 del modelo. La lectura correcta es que el clasificador no es la mejor herramienta cuando el sistema expone el costo. Su valor está en tres usos. Evalúa una línea cuando el costo no está disponible para quien captura el pedido, sirve como segundo método independiente para fijar los topes y confirma, sin usar costo, que la pérdida depende del

descuento y la subcategoría. En productos sin historial hubo 107 líneas y 11 pérdidas, muestra muy chica para afirmar que el modelo supere a la regla ahí (F1 0.696 contra 0.727).

Topes de descuento. El entregable para el negocio es la tabla de topes, calculada con dos métodos independientes y solo con 2014 a 2016. Por costo, el percentil 10 del descuento de equilibrio de cada subcategoría, que deja rentables al 90% de las líneas. Por modelo, el mayor descuento con probabilidad de pérdida bajo el umbral. Se toma el menor, y que ambos coincidan en orden de magnitud es una prueba de consistencia.

Subcategoría	Desc. prom.	Desc. máx.	Líneas con pérdida	Tope costo	Tope modelo	Tope	Utilidad recuperada 2017
Binders	37%	80%	40%	45%	30%	**30%**	$26,078
Tables	26%	50%	63%	10%	25%	**10%**	$17,035
Machines	31%	70%	40%	25%	30%	**25%**	$11,570
Chairs	17%	30%	36%	10%	25%	**10%**	$9,929
Bookcases	21%	70%	47%	5%	25%	**5%**	$6,510
Storage	7%	20%	19%	0%	15%	**0%**	$5,030
Phones	15%	40%	14%	25%	25%	**25%**	$3,643
Appliances	16%	80%	13%	25%	30%	**25%**	$2,804
Furnishings	14%	60%	19%	15%	25%	**15%**	$2,763
Accessories	8%	20%	13%	10%	25%	**10%**	$1,942
Supplies	8%	20%	18%	0%	25%	**0%**	$1,720
Copiers	17%	40%	0%	35%	40%	**35%**	$125
Fasteners	9%	20%	7%	0%	25%	**0%**	$71
Art	7%	20%	0%	25%	40%	**25%**	$0
Envelopes	8%	20%	0%	45%	30%	**30%**	$0
Paper	7%	20%	0%	45%	40%	**40%**	$0
Labels	7%	20%	0%	45%	30%	**30%**	$0

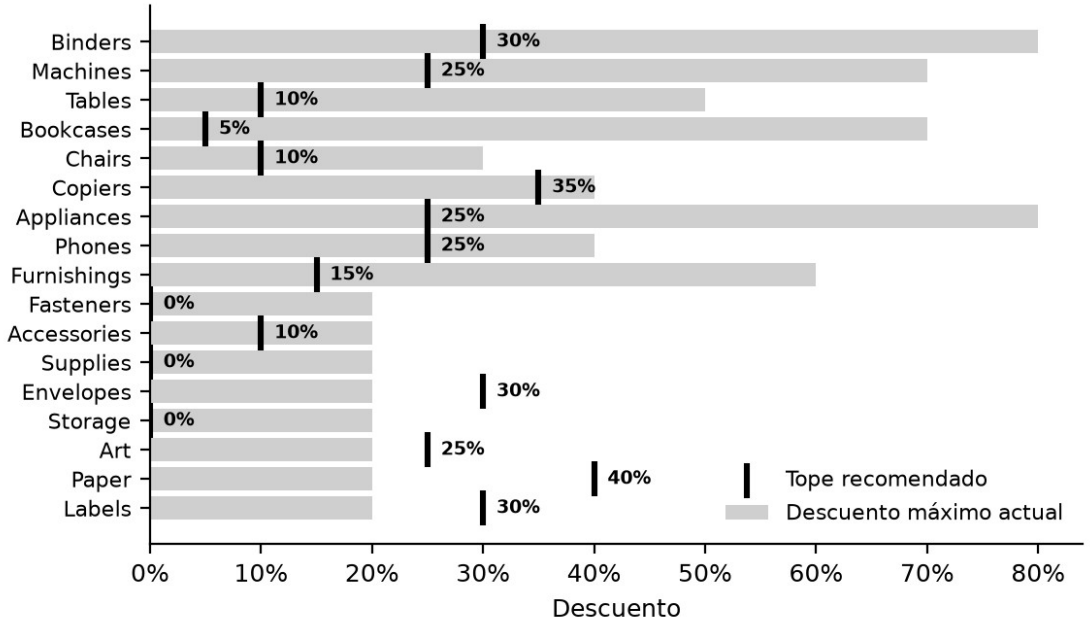


Figura 2. Descuento máximo que se aplica hoy contra el tope recomendado. Donde la barra gris rebasa la marca negra, la política actual genera pérdidas.

Simulación sobre 2017. Con el costo unitario real se recalculó la utilidad de cada línea bajo el tope. Cambian 925 líneas, el 28% del año. Las líneas con pérdida bajan de 620 a 49. Como el volumen podría caer al subir el precio neto, se probaron escenarios de pérdida de volumen en las líneas afectadas. La refutación de H2 sugiere que el escenario realista está cerca de cero.

Escenario de volumen en líneas afectadas	Utilidad 2017	Cambio contra real
Real, sin topes	$93,439	$0
Se mantiene el volumen	$182,660	+$89,220
Se pierde el 10%	$178,343	+$84,904
Se pierde el 25%	$171,869	+$78,430
Se pierde el 50%	$161,078	+$67,639
Se pierde el 100%	$139,497	+$46,058

9.2 Entregas fuera de tiempo

Técnica. El dataset no trae la promesa de entrega, así que se definió como supuesto. Same Day 0 días, First Class 2, Second Class 3 y Standard Class 5. Como la modalidad define el rango de días, la pregunta es si dentro de cada modalidad algo explica el retraso. Se respondió con 24 pruebas chi-cuadrada con corrección de Bonferroni (alfa 0.0021, V de Cramér como tamaño de efecto) y con regresión logística y gradient boosting por modalidad con la misma partición temporal.

Modalidad	Pedidos	Fuera de promesa	Días p95	AUC logística	AUC boosting
Same Day	264	4.5%	0	0.58	0.17
First Class	787	40.2%	3	0.46	0.49
Second Class	964	41.2%	5	0.52	0.52
Standard Class	2,994	30.2%	7	0.46	0.49

Ninguna prueba es significativa. El p-valor mínimo es 0.015 y la V de Cramér máxima 0.17. Los modelos obtienen AUC entre 0.46 a 0.52, equivalente a adivinar. Same Day tiene solo 5 pedidos tarde en 2017 y su AUC no es interpretable. El problema real es la promesa. Second Class entrega en 4 o 5 días el 41% de las veces, lo que hoy se espera de Standard Class.

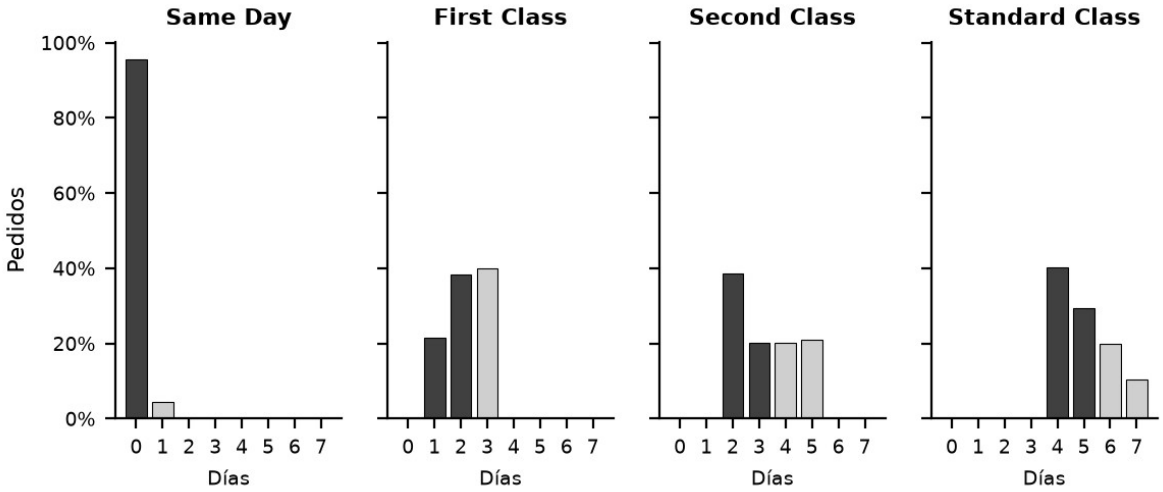


Figura 3. Distribución de días de envío por modalidad. En gris oscuro los pedidos dentro de la promesa supuesta, en gris claro los que la exceden.

Modalidad	Promesa actual	Cumplimiento actual	Promesa p95	Cumplimiento p95
Same Day	0 días	95%	0 días	95%
First Class	2 días	60%	3 días	100%
Second Class	3 días	59%	5 días	100%
Standard Class	5 días	70%	7 días	100%

9.3 Segmentación de clientes

Técnica. No hay etiqueta de tipo de cliente, así que se usó aprendizaje no supervisado. K-Means es interpretable por sus centroides y adecuado para variables continuas estandarizadas. Variables, recencia al 31 de diciembre de 2017, logaritmo de frecuencia, logaritmo de monto, margen recortado en percentiles 1 y 99, y descuento promedio.

Número de grupos. Se evaluó k de 2 a 8 con inercia, silueta y Davies-Bouldin. La regla fue tomar, entre 3 y 6, el menor k cuyo Davies-Bouldin quedara a menos de 1% del mínimo. Resultó k = 4 (Davies-Bouldin 1.335 contra 1.330 de k = 5), que coincide con el codo. La silueta de 0.22 indica separación moderada. Con 20 semillas el índice de Rand ajustado es 0.98 y con 50 remuestreos bootstrap 0.72, mejor que k = 3 (0.63).

Grupo	Clientes	Ventas prom.	Pedidos	Días sin comprar	Desc.	Margen	Utilidad	Pérdidas
Alto valor rentable	347	$4,285	7.9	91	12.4%	18.4%	101%	29%
Cazadores de descuento	201	$2,601	6.6	88	24.4%	-5.4%	-16%	62%
Compradores ocasionales	172	$1,092	4.1	144	10.0%	21.0%	13%	2%
Inactivos	73	$1,362	3.3	595	21.6%	-0.2%	1%	7%

10 Insights

Cada insight dice qué encontramos, por qué importa y qué hacer.

1. **La pérdida es una política, no un error humano.** El 93% de las pérdidas está en 10 estados con descuento promedio mayor a 25%. Importa porque se corrige cambiando una tabla, sin capacitar a nadie. Acción, reescribir la tabla de descuentos de esos estados.
2. **El descuento no compra volumen.** La cantidad por línea no cambia con el descuento (H2). Importa porque el miedo a perder ventas es la principal objeción a los topes. Acción, aplicar topes con un piloto que mida el efecto real.
3. **Vender mucho no es ser rentable.** El margen del cliente no se relaciona con cuánto compra, sino con el descuento que recibe (H7). Los Cazadores de descuento hacen el 60% de sus compras en los estados de descuento alto. Acción, ofrecerles servicio y no precio.
4. **El modelo encuentra la zona gris.** Con 20% de descuento la regla no ve nada y el modelo detecta 94 de 169 pérdidas (H8). Acción, usar el evaluador de línea solo en ese rango, donde aporta.
5. **El retraso es un problema de promesa.** No depende de región, cliente ni temporada (H5), y no explica el abandono de clientes (H6). Acción, prometer 3, 5 y 7 días y empezar a registrar transportista y entrega real.
6. **La segmentación oficial no sirve para decidir.** Consumer, Corporate y Home Office pierden en la misma proporción (H3) y se reparten igual entre los cuatro grupos. Acción, usar los grupos del modelo para presupuesto de marketing.

11 Decisión de negocio

Decisión. Aplicar los topes de descuento por subcategoría en los 10 estados de descuento alto a partir del siguiente trimestre, en dos olas de cinco estados de seis semanas cada una, y extenderlos al resto del país solo si se cumplen los criterios de éxito.

Opción	Utilidad 2017 simulada	Riesgo
A. Mantener la política actual	$93,439	Sigue perdiendo dinero en 10 estados
B. Topes en todo el país de inmediato	$182,660	No mide el efecto real en volumen antes de escalar
C. Topes en los 10 estados en dos olas, el resto después	$174,880	Bajo. La primera ola sirve de experimento contra la segunda

Por qué C y no B. La opción C captura el 91% del beneficio de la opción B con 815 de las 925 líneas afectadas. Además resuelve la principal limitación del análisis, que no observa cómo reacciona el cliente a un precio más alto. Mientras la primera ola corre, los cinco estados de la segunda funcionan como grupo de control, y la diferencia entre ambos mide el efecto real en volumen antes de escalar. La decisión es reversible porque solo cambia una tabla.

Semana	Acción	Responsable
1 a 2	Aprobar la tabla de topes y cargarla en el sistema de ventas	Finanzas
3 a 8	Ola 1 en cinco estados, los otros cinco como control	Comercial
9 a 14	Ola 2 en los cinco restantes	Comercial
15	Revisión con datos reales y decisión de extender al resto del país	Dirección
En paralelo	Nueva promesa de entrega y campañas por grupo de cliente	Operaciones y Marketing

Criterios de éxito. Líneas con pérdida menores a 5% en los estados tratados. Pedidos por cliente activo sin caer más de 10% contra el grupo de control. Margen neto positivo en los 10 estados. **Criterio de alto.** Si los pedidos por cliente caen más de 25% contra el control, se revisan los topes de las subcategorías con mayor caída antes de la segunda ola.

12 Score, regla y decisión humana

Los modelos apoyan decisiones, no las toman. Cada salida analítica pasa por tres pasos con dueño claro. El **score** es lo que calcula el modelo. La **regla** es una política explícita y auditable que convierte el score en una recomendación. La **decisión** la toma una persona, que puede aceptar, ajustar o rechazar la recomendación y deja registro de por qué.

Nivel	Score	Regla	Decide
Línea de venta	Probabilidad de pérdida del modelo	Rojo si el descuento supera el tope de la subcategoría. Amarillo si está dentro del tope pero el score supera el umbral. Verde en otro caso	Gerente comercial en rojo y amarillo, vendedor en verde
Política de descuento	Utilidad simulada por subcategoría y estado	Tope igual al menor entre el percentil 10 del descuento de equilibrio y el tope del modelo	Director de finanzas aprueba la tabla
Promesa de entrega	Percentil 95 de días por modalidad	La promesa publicada es el percentil 95 redondeado hacia arriba	Gerente de operaciones
Cliente	Grupo asignado por K-Means	Acción sugerida por grupo (proteger, corregir, crecer, reactivar)	Gerente de marketing asigna presupuesto
Estrategia	Resultados de la ola 1 contra el grupo de control	Extender si se cumplen los criterios de éxito, revisar si se activa el criterio de alto	Dirección general

Semáforo para cada línea de venta. Rojo si el descuento supera el tope de la subcategoría, con recomendación de ajustarlo al tope. Amarillo si está dentro del tope pero el score supera el umbral de 0.45, con recomendación de revisar el margen del producto. Verde en otro caso. En rojo y amarillo decide el gerente comercial entre ajustar, aprobar una excepción con justificación o rechazar la venta. En verde el vendedor sigue el proceso normal.

Semáforo	Líneas 2017	Por mes	Tasa de pérdida	Monto perdido que concentra
Rojo	925	77	65%	99.2%
Amarillo	4	0	75%	0.1%
Verde	2,383	199	1%	0.7%

La carga para el área es manejable. Unas 77 líneas al mes requieren a una persona y en ellas está el 99.3% del monto perdido. Las líneas en verde pierden dinero en menos de 1% de los casos. El dashboard registra cada decisión con fecha, responsable y justificación en una bitácora, lo que permite auditar las excepciones y medir si la regla necesita ajuste.

La decisión estratégica de la sección 11 sigue la misma lógica. El score son los resultados de la ola 1 contra el grupo de control, la regla son los criterios de éxito y de alto, y la decisión de extender la política al resto del país es de Dirección General.

13 Despliegue, BI y monitoreo

El resultado se entrega como un producto de BI con modelos de aprendizaje de máquina integrados, no como un análisis aislado.

Capa	Qué hace	Implementación
Fuente	Datos transaccionales de ventas	CSV de Superstore, en producción el ERP
ETL	Extrae, valida, limpia y deriva variables	src/etl.py con validaciones en JSON
Modelo de datos	Estrella con hechos y dimensiones	data/processed/bi
Modelos	Clasificación, análisis de entregas, clustering	scikit-learn, versionados en models/
Consumo	Un tablero por área con KPIs y simuladores	Streamlit, o Power BI y Looker sobre el modelo estrella

El dashboard tiene una pestaña por área. Dirección ve KPIs y la lectura cruzada. Hipótesis y decisión muestra las pruebas, las reglas y las opciones. Comercial tiene el evaluador de línea con score, semáforo y un formulario para registrar la decisión humana. Finanzas ve la simulación y el mapa de utilidad por estado y subcategoría. Operaciones ve tiempos reales por modalidad. Marketing ve los grupos de clientes con su acción sugerida.

Monitoreo. Cada trimestre se reentrena el modelo de pérdida con los datos nuevos y se recalculan los topes. Se vigila la distribución del descuento y del precio de lista, porque un cambio de política o de catálogo invalida el modelo. Una alerta se dispara si las líneas con pérdida superan 5% en cualquier estado, o si el F1 en el trimestre más reciente cae por debajo del de la regla simple.

14 Conclusiones

La primera pregunta analítica tiene respuesta positiva. Con la información disponible al capturar un pedido se puede anticipar si una línea perderá dinero, y un gradient boosting lo hace mejor que la regla actual (F1 de 0.889 contra 0.826). Su mayor aporte está en la zona gris del 20% de descuento, donde la regla no ve nada. De ahí se derivan topes por subcategoría que, aplicados a 2017, habrían llevado la utilidad de $93,439 a $182,660. El matiz importante es que una regla con el costo histórico del producto detecta las pérdidas mejor que cualquier modelo (F1 0.995), así que en operación conviene usar el costo donde exista y el modelo donde no.

La segunda pregunta tiene respuesta negativa y es igual de útil. Con los datos actuales el retraso no se puede predecir dentro de cada modalidad. El problema de Operaciones no es priorizar pedidos sino prometer tiempos que no se cumplen.

La tercera pregunta tiene respuesta positiva. Existen cuatro grupos de clientes con rentabilidades muy distintas, estables entre semillas (índice de Rand ajustado 0.98) y moderadamente estables en remuestreo (0.72), y la segmentación oficial no los distingue. El grupo Cazadores de descuento resta utilidad y el de Alto valor rentable la genera toda.

Las tres respuestas apuntan a la misma causa. La pérdida se concentra en 10 estados con descuento alto (93% del monto perdido), no depende del tipo de cliente y no se relaciona con la logística (el retraso va de 27% a 33% entre grupos). Siete de ocho creencias del negocio resultaron falsas, lo que confirma el valor de probar antes de construir.

15 Recomendaciones

Cada recomendación cumple los criterios de la sección 4.2 y tiene un responsable que decide.

Área	Recomendación	Evidencia
Dirección	Aprobar la opción C, topes en los 10 estados de descuento alto en dos olas, y decidir en la semana 15 si se extiende al resto del país.	91% del beneficio posible con riesgo bajo
Finanzas	Reemplazar la tabla de descuentos por estado con los topes por subcategoría, empezando por Binders, Tables, Machines y Chairs.	+$89,220 en 2017, +$46,058 en el peor caso
Comercial	Usar el semáforo del dashboard en cada línea con descuento y registrar en bitácora toda excepción con su justificación.	Unas 77 revisiones al mes cubren el 99.3% del monto perdido
Operaciones	Publicar la promesa de 3, 5 y 7 días y empezar a registrar transportista, almacén y fecha real de entrega.	Retraso no predecible, AUC de 0.46 a 0.52
Marketing	Lealtad sin descuento para Alto valor rentable, servicio en vez de precio para Cazadores, recompra para Compradores ocasionales.	Cuatro grupos, ARI bootstrap 0.72 y silueta 0.22

16 Reproducibilidad y uso de inteligencia artificial

16.1 Reproducibilidad

Todo el proyecto está escrito en Python y se regenera desde el CSV original con un solo comando. La configuración, la semilla 42 y los supuestos de negocio viven en src/config.py. Las versiones de las librerías quedan fijas en uv.lock, y la prueba test_resultados_reproducibles compara cada corrida contra los números de referencia que citan los entregables. La integración continua corre el pipeline y las pruebas en cada cambio.

Paso	Comando
Instalar dependencias	uv sync (versiones fijas en uv.lock)
Ejecutar el pipeline completo	uv run python src/run_all.py
Verificar resultados	uv run pytest -q
Abrir el dashboard	uv run streamlit run app/dashboard.py
Generar los entregables	uv run python reports/build_entregables.py
Notebook en Google Colab	notebooks/rolulabo_analisis.ipynb, la primera celda clona el repositorio e instala las versiones fijas

16.2 Declaración de uso de inteligencia artificial

El equipo usó Claude, de Anthropic, como asistente para estructurar el código del pipeline y del dashboard, revisar la metodología de validación, auditar el proyecto contra la rúbrica y redactar borradores de los documentos. El equipo definió el problema, eligió el alcance, ejecutó y revisó cada resultado, y es responsable de las interpretaciones, la decisión y las recomendaciones. Todas las cifras provienen de la ejecución del código incluido. El detalle de herramientas y verificaciones está en el documento Declaración de herramientas.

17 Referencias

Chapman, P. et al. (2000). CRISP-DM 1.0. Step-by-step data mining guide. SPSS.

Chowdhury, V. (2022). Superstore Dataset. Kaggle. https://www.kaggle.com/datasets/vivek468/superstore-dataset-final

Kimball, R. y Ross, M. (2013). The Data Warehouse Toolkit, 3a edición. Wiley.

Pedregosa, F. et al. (2011). Scikit-learn. Machine Learning in Python. Journal of Machine Learning Research, 12, 2825 a 2830.

Rousseeuw, P. J. (1987). Silhouettes. A graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, 20, 53 a 65.

Saito, T. y Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. PLOS ONE, 10(3).

Schwaber, K. y Sutherland, J. (2020). The Scrum Guide. scrumguides.org.

Elaborado por Gabriel Álvarez Mendoza, Eduardo Gutiérrez, Emiliano Luna y Rodrigo Naranjo Hernández